

ESTADÍSTICA MORTAL

El Enigma del Conjunto Vacío

Una Novela de Misterio, Datos y Probabilidades

Autor: Alex Goyzueta Delgado

Contacto: alexgoyzueta2018@gmail.com

"En los datos se esconde la verdad.

En la probabilidad, la certeza."

Barcelona, 2026

Créditos

Estadística Mortal: El Enigma del Conjunto Vacío

© 2026 Alex Goyzueta Delgado

Todos los derechos reservados. Ninguna parte de esta publicación puede ser reproducida, distribuida o transmitida en forma alguna ni por ningún medio electrónico, mecánico, fotocopia, grabación u otro método, sin el permiso previo por escrito del autor.

Edición y corrección: Alex Goyzueta Delgado

Ilustraciones conceptuales: Generadas mediante descripciones textuales

Diseño de portada: Alex Goyzueta Delgado

Tipografía: IBM Plex Mono (código), Lato (narrativa)

Agradecimientos especiales:

A los estadísticos que enseñan con pasión.

A la comunidad Python de Latinoamérica.

A todos los que creen que los datos pueden cambiar el mundo.

Datos de catalogación:

Goyzueta Delgado, Alex

Estadística Mortal: El Enigma del Conjunto Vacío / Alex Goyzueta Delgado

1ra edición — Barcelona, 2026

Dedicatoria

A todos los que alguna vez miraron un número y vieron una historia.

A los que saben que detrás de cada estadística hay una vida, una decisión, un misterio.

Y a los estudiantes que creen que las matemáticas no son su fuerte: este libro es para demostrarles que están equivocados.

Prefacio

Este libro nace de una idea simple: la estadística y la probabilidad no son aburridas. Son herramientas para contar historias, para descubrir verdades ocultas, para resolver misterios.

Cada capítulo combina tres elementos:

- Una historia que avanza la trama de un crimen por resolver

- Conceptos de estadística y probabilidad explicados desde cero
- Código Python que puedes ejecutar para ver los conceptos en acción

No necesitas saber estadística para leer este libro. Los conceptos se introducen gradualmente, desde lo más básico hasta lo más avanzado. Tampoco necesitas ser experto en Python —cada línea de código está explicada—, aunque si ya tienes algo de experiencia, podrás enfocarte más en los conceptos estadísticos.

La historia está ambientada en Barcelona, 2026, una ciudad donde la tecnología y los datos lo gobiernan todo. Los personajes, aunque ficticios, reflejan problemas reales: manipulación de datos, fraude académico, corrupción y la lucha por la verdad en un mundo donde la información es poder.

Al final de cada capítulo encontrarás enigmas para resolver. Las soluciones están en el Apéndice, pero te recomiendo intentarlos antes de mirar la respuesta.

Bienvenido a Estadística Mortal.

Tu viaje comienza aquí.

Introducción

Barcelona, 2026

Imagina una ciudad donde los algoritmos predicen el tráfico antes de que los autos se muevan. Donde los datos fluyen por la fibra óptica como el agua por las ramblas históricas. Donde cada transacción, cada llamada, cada paso deja una huella digital.

Esa es Barcelona.

Una metrópoli que late al ritmo de los datos. Aquí, la información es el recurso más valioso. Y como todo recurso valioso, hay quienes están dispuestos a matar por él.

El Instituto de Ciencias de Datos

El ICD —Instituto de Ciencias de Datos— es el centro de investigación más importante de Sudamérica. Ubicado en el antiguo barrio de San Blas, combina arquitectura colonial con laboratorios de última generación. Sus investigadores publican en las mejores revistas del mundo. Sus algoritmos optimizan desde la distribución de agua hasta la predicción de terremotos.

Pero detrás de los números y las publicaciones, algo oscuro se esconde.

El proyecto Yupay

La Dra. Kamila Huamán, jefa del departamento de Estadística del ICD, lideraba el proyecto más ambicioso del instituto: Yupay (contar, en quechua). Un sistema de modelos predictivos capaz de anticipar crisis sociales, económicas y ambientales con una precisión del 98%.

Pero Yupay no era solo un proyecto académico. Sus modelos habían detectado algo. Algo que alguien no quería que se supiera.

El crimen

Todo comienza una madrugada en el laboratorio 7 del ICD. La Dra. Kamila Huamán aparece muerta en su oficina. La puerta estaba cerrada por dentro. Su computadora, encendida. En la pantalla, solo una línea de código:

```
datos = []
```

Un conjunto vacío.

La policía dice que fue un paro cardíaco. La universidad dice que fue un accidente.

Valeria Quispe, una joven analista de datos exalumna de la Dra. Huamán, sabe que el conjunto vacío no es un error. Es un mensaje.

Y tú la vas a ayudar a descifrarlo.

Capítulo 1: El Conjunto Vacío

Conceptos: Estadística descriptiva — media, mediana, moda, min, max

Valeria Quispe cerró la puerta de su departamento en el barrio de San Blas y se dejó caer en la silla frente a su computadora. Eran las 7:23 a.m. del 3 de julio y el sol apenas comenzaba a iluminar las calles empedradas de Barcelona.

El mensaje había llegado a las 6:15 a.m.:

```
Valeria:
Sé que fuiste su alumna favorita.
Esto no fue un ataque al corazón.
Ven al ICD. Trae tu laptop.
— C
```

Valeria había sido alumna de la Dra. Kamila Huamán en su último año de la maestría en Ciencia de Datos. Kamila no solo le había enseñado estadística; le había enseñado a pensar. "Los números no mienten", decía siempre. "Las personas, sí."

El ICD estaba a quince minutos caminando. Valeria recorrió las calles de San Blas esquivando turistas y vendedores ambulantes. La fachada del instituto era imponente: un edificio de vidrio negro que reflejaba las montañas circundantes.

En la entrada la esperaba un hombre joven, de unos treinta años, con una laptop bajo el brazo y una expresión seria.

—¿Valeria? —dijo extendiendo la mano—. Soy Marco. Marco Tupac. Trabajé con la doctora Huamán en el proyecto Yupay.

—Tú enviaste el mensaje.

—Sí. Ven, te explico todo.

La escena

El laboratorio 7 estaba intacto. La policía había terminado su investigación y lo habían declarado "muerte natural". Pero Marco no lo creía.

—Mira esto —dijo Marco, señalando la pantalla de la computadora de la doctora—. Cuando llegué esa mañana, esto era lo único que había en la pantalla.

```
datos = []
```

Valeria observó la línea en silencio.

—Es una lista vacía —dijo—. En Python, `[]` es un conjunto vacío. No tiene elementos.

—¿Por qué alguien dejaría una lista vacía en su pantalla antes de morir?

—Kamila no hacía nada sin razón. Enséñame sus archivos.

Marco abrió el explorador de archivos. En el escritorio había una carpeta llamada `Yupay/`. Dentro, un único archivo:

```
datos_caso.csv
```

Valeria abrió el archivo. Era un CSV con datos de un estudio clínico. Pero algo extraño: la mayoría de los campos estaban vacíos.

—Son datos falsos —dijo Marco—. O incompletos. No lo sé.

—No —respondió Valeria—. No son falsos. Son un mensaje. Kamila me enseñó que los datos siempre hablan. Solo hay que saber escucharlos.

Estadística descriptiva: el lenguaje de los datos

Valeria abrió su terminal. Si iba a entender qué había pasado, primero necesitaba entender los datos.

—La estadística descriptiva —dijo Valeria, más para sí misma que para Marco— es la forma más básica de entender un conjunto de datos. Responde preguntas como: ¿cuántos datos tenemos? ¿Cuál es el valor típico? ¿Qué tan dispersos están?

—Suená útil —dijo Marco—. Pero ¿cómo nos ayuda a encontrar a un asesino?

—Empecemos con lo básico.

Valeria abrió Python y comenzó a escribir:

```
import csv
# Cargamos los datos del archivo misterioso
datos_caso = []
with open('datos_caso.csv', 'r') as archivo:
    lector = csv.reader(archivo)
    encabezados = next(lector)
    for fila in lector:
        datos_caso.append(fila)
print(f"Archivo cargado: {len(datos_caso)} registros encontrados")
print(f"Columnas: {encabezados}")
```

—Primero, veamos los datos resumidos.

Valeria continuó:

```
# Extraemos las edades de los pacientes
edades = []
for fila in datos_caso:
    if fila[2]: # La columna 2 tiene las edades
        edades.append(int(fila[2]))
print(f"\n=== RESUMEN DE EDADES ===")
print(f"Cantidad total (n):    {len(edades)}")
print(f"Edad mínima (min):     {min(edades)}")
print(f"Edad máxima (max):      {max(edades)}")
```

Resultado:

```
=== RESUMEN DE EDADES ===
Cantidad total (n):    47
Edad mínima (min):    22
Edad máxima (max):    78
```

—¿Y eso qué significa? —preguntó Marco.

—Que tenemos 47 pacientes con edades entre 22 y 78 años. Pero esto no me dice nada sobre el valor típico. Necesito la media —el promedio— y la mediana —el valor central—.

```
# Media (promedio)
media = sum(edades) / len(edades)
print(f"Edad media (promedio): {media:.2f} años")
# Mediana (valor central)
edades_ordenadas = sorted(edades)
n = len(edades_ordenadas)
if n % 2 == 0:
    mediana = (edades_ordenadas[n//2 - 1] + edades_ordenadas[n//2]) / 2
else:
    mediana = edades_ordenadas[n//2]
print(f"Edad mediana (central): {mediana:.2f} años")
# Moda (valor más frecuente)
from collections import Counter
conteo_edades = Counter(edades)
edad_moda, frecuencia_moda = conteo_edades.most_common(1)[0]
```

```
print(f"Edad moda (frecuente): {edad_moda} años ({frecuencia_moda} veces)")
```

Resultado:

```
Edad media (promedio): 47.89 años
Edad mediana (central): 48.00 años
Edad moda (frecuente): 45 años (5 veces)
```

—La media es 47.89, la mediana es 48, la moda es 45. Están cerca —dijo Valeria—. Eso sugiere que los datos tienen una distribución bastante simétrica. Nada sospechoso.

—Entonces, ¿todo es normal?

—No. Porque lo interesante no son los datos que están aquí. Son los datos que faltan.

El conjunto vacío

Valeria señaló la pantalla.

—Mira la lista vacía otra vez: `datos = []`. Kamila no escribió eso por accidente. Me está diciendo que mire los datos que no están.

```
# Identificando datos faltantes
total_filas = len(datos_caso)
faltantes_por_columna = []
for i, encabezado in enumerate(encabezados):
    faltan = sum(1 for fila in datos_caso if not fila[i].strip())
    faltantes_por_columna.append((encabezado, faltan))
    porcentaje = (faltan / total_filas) * 100
    if faltan > 0:
        print(f"Columna '{encabezado}': {faltan} valores faltantes ({porcentaje:.1f}%)")
```

Resultado:

```
Columna 'diagnostico': 2 valores faltantes (4.3%)
Columna 'medicamento': 12 valores faltantes (25.5%)
Columna 'resultado': 1 valores faltantes (2.1%)
Columna 'notas_doctor': 47 valores faltantes (100.0%)
```

—Espera —dijo Marco—. La columna `notas\_doctor` está completamente vacía.

—Exacto. Un conjunto vacío dentro de los datos. Y mira esto —Valeria seleccionó la columna de medicamentos—. El 25.5% de los valores de medicamentos faltan. Eso es un patrón sospechoso.

—¿Crees que alguien borró esos datos a propósito?

—No lo sé. Pero Kamila sí lo sabía. Y por eso dejó el mensaje.

Valeria se recostó en la silla y miró la pantalla.

—Necesito más información. La media, la mediana y el rango me dicen algo, pero no suficiente. Necesito entender la dispersión de los datos. La varianza y la desviación estándar.

—¿Y eso qué es?

—Se lo explicaré en el camino. Primero, dime: ¿quién más tenía acceso a este laboratorio?

Marco dudó. Sacó su teléfono y mostró una lista.

—Había cuatro personas con acceso: la doctora Huamán, el director del instituto, su asistente... y el encargado de seguridad de datos.

—¿Y quién es el encargado de seguridad?

—Se llama Ramiro. Ramiro Quispe.

Valeria sintió un escalofrío. Quispe. Su mismo apellido. Perú era un país donde los apellidos se repetían, pero algo en la forma en que Marco lo dijo la puso alerta.

—Necesito hablar con él.

—Hay un problema —dijo Marco—. Ramiro renunció ayer. Desapareció.

Tu primer enigma

Enigma 1.1: Analiza tu propio conjunto

Tienes las siguientes edades de un grupo de sospechosos:

```
edades_sospechosos = [29, 34, 45, 45, 45, 52, 67, 71, 34, 29, 45, 38, 52, 45, 29]
```

Calcula:

1. La media
2. La mediana
3. La moda
4. El mínimo y máximo

Enigma 1.2: El outlier

Agrega a la lista anterior la edad de un nuevo sospechoso: 98 años. ¿Cómo cambian la media y la mediana? ¿Cuál de las dos medidas se ve más afectada por este valor extremo?

Enigma 1.3: Datos faltantes

En el archivo `datos\_caso.csv`, la columna `presion\_sanguinea` tiene 5 valores vacíos de 47. ¿Qué porcentaje de datos falta? Si estos valores fueran borrados intencionalmente, ¿qué información estaría ocultando el responsable?

Lo que aprendiste

- La estadística descriptiva resume un conjunto de datos con medidas clave
- Media: el promedio aritmético (sensible a valores extremos)
- Mediana: el valor central cuando los datos están ordenados (robusta)
- Moda: el valor que más se repite
- Mínimo y máximo: definen el rango de los datos
- Los datos faltantes pueden ser una señal de manipulación
- `[]` en Python es una lista vacía — un conjunto vacío

Valeria guardó su análisis en un archivo llamado `analisis\_inicial.py` y miró a Marco.

—Ramiro Quispe desapareció justo después de la muerte de Kamila. Eso no es una coincidencia. Pero antes de buscarlo, necesito entender mejor estos datos. Algo no encaja.

—¿Qué?

Valeria señaló la columna de edades.

—La media y la mediana son casi iguales. Eso ocurre cuando los datos tienen una distribución normal. Pero los datos clínicos rara vez son perfectos. Alguien ajustó estos números. Y ajustar datos es... estadísticamente mortal.

La noche caía sobre Barcelona. El misterio apenas comenzaba.

Capítulo 2: La Probabilidad del Crimen

Conceptos: Probabilidad básica, espacio muestral, eventos, regla de Laplace

Marco llevó a Valeria a la cafetería del ICD, un espacio abierto en el tercer piso con vistas a la cordillera. El

sol de la mañana iluminaba los picos nevados mientras ellos se sentaban en una mesa apartada.

—Tengo que contarte algo —dijo Marco en voz baja—. La noche antes de morir, Kamila me envió un mensaje. Decía que había encontrado algo en los datos. Algo que no debía existir.

—¿Qué era?

—No lo sé. Dijo que era como... una irregularidad estadística. Una probabilidad imposible.

Valeria sacó su laptop.

—Dime exactamente lo que te dijo.

—Dijo: "La probabilidad de que esto ocurra al azar es una en un millón. Literalmente." Y luego me envió un archivo.

—¿Qué archivo?

—Este.

Marco le pasó una memoria USB. Valeria la conectó. Dentro había un solo archivo:

```
distribucion_sospechosa.csv
```

Valeria lo abrió. Eran 1000 registros con dos columnas: `tratamiento` y `resultado`.

—Son datos de un ensayo clínico —dijo Valeria—. Pero hay algo raro en la distribución.

Probabilidad: el lenguaje del azar

Valeria abrió Python.

—Para entender qué vio Kamila, primero tenemos que entender la probabilidad. La probabilidad mide qué tan probable es que ocurra un evento. Va de 0 (imposible) a 1 (seguro).

—Eso lo sé —dijo Marco—. Como cuando la probabilidad de lluvia es del 30%.

—Exacto. Pero la forma correcta de calcularla es con la regla de Laplace:

$$P(\text{evento}) = \frac{\text{casos favorables}}{\text{casos posibles}}$$

—Por ejemplo, si lanzas una moneda, la probabilidad de que salga cara es $1/2 = 0.5$. Si lanzas un dado, la probabilidad de que salga un 6 es $1/6 \approx 0.1667$.

Valeria escribió en Python:

```
# Probabilidad básica con Python
import random
# Simular lanzamiento de una moneda
caras = 0
total_lanzamientos = 1000
for _ in range(total_lanzamientos):
    if random.random() < 0.5: # 50% de probabilidad
        caras += 1
probabilidad_estimada = caras / total_lanzamientos
print(f"Lanzamientos: {total_lanzamientos}")
print(f"Caras obtenidas: {caras}")
print(f"Probabilidad estimada: {probabilidad_estimada:.4f}")
print(f"Probabilidad teórica: 0.5")
```

Resultado:

```
Lanzamientos: 1000
Caras obtenidas: 513
Probabilidad estimada: 0.5130
Probabilidad teórica: 0.5
```

—La probabilidad estimada se acerca a la teórica mientras más lanzamientos hagamos. Eso es la ley de los grandes números.

—Entonces, ¿qué vio Kamila en los datos del ensayo clínico?

La distribución sospechosa

Valeria cargó el archivo en Python:

```
import csv
from collections import Counter
datos_ensayo = []
with open('distribucion_sospechosa.csv', 'r') as f:
    lector = csv.DictReader(f)
    for fila in lector:
        datos_ensayo.append(fila)
print(f"Total de pacientes: {len(datos_ensayo)}")
# Contar resultados por tratamiento
resultados = Counter()
for paciente in datos_ensayo:
    clave = (paciente['tratamiento'], paciente['resultado'])
    resultados[clave] += 1
print("\n=== RESULTADOS DEL ENSAYO ===")
for (tratamiento, resultado), conteo in sorted(resultados.items()):
    print(f"Tratamiento '{tratamiento}' - Resultado '{resultado}': {conteo}")
```

Resultado:

```
Total de pacientes: 1000
=== RESULTADOS DEL ENSAYO ===
Tratamiento 'A' - Resultado 'mejora': 470
Tratamiento 'A' - Resultado 'no_mejora': 30
Tratamiento 'B' - Resultado 'mejora': 240
Tratamiento 'B' - Resultado 'no_mejora': 260
```

—Mira esto —dijo Valeria—. Del grupo que recibió el tratamiento A, 470 de 500 pacientes mejoraron. Eso es una tasa de éxito del 94%. Del grupo B, solo 240 de 500 mejoraron: 48%.

—Entonces el tratamiento A funciona mucho mejor.

—Sí, pero la pregunta es: ¿cuál es la probabilidad de que esta diferencia se deba al azar?

Valeria continuó:

```
total_pacientes = 1000
# Probabilidad de mejora con tratamiento A
p_A_mejora = 470 / 500
print(f"P(mejora | Tratamiento A) = {p_A_mejora:.3f}")
# Probabilidad de mejora con tratamiento B
p_B_mejora = 240 / 500
print(f"P(mejora | Tratamiento B) = {p_B_mejora:.3f}")
# Diferencia observada
diferencia = p_A_mejora - p_B_mejora
print(f"Diferencia observada: {diferencia:.3f}")
# ¿Cuál es la probabilidad general de mejora?
p_mejora_general = (470 + 240) / 1000
print(f"P(mejora general) = {p_mejora_general:.3f}")
```

Resultado:

```
P(mejora | Tratamiento A) = 0.940
P(mejora | Tratamiento B) = 0.480
Diferencia observada: 0.460
P(mejora general) = 0.710
```

—La diferencia es enorme: 46 puntos porcentuales. Kamila dijo que era una probabilidad en un millón. Vamos a comprobarlo.

```
# Simulación: si el tratamiento no tuviera efecto,
# ¿con qué frecuencia veríamos una diferencia tan grande?
import random
simulaciones = 10000
diferencias_extremas = 0
resultados_totales = [1] * 710 + [0] * 290 # 710 mejoras, 290 no mejoras
for _ in range(simulaciones):
```



```

random.shuffle(resultados_totales)
grupo_A = resultados_totales[:500]
grupo_B = resultados_totales[500:]
p_A = sum(grupo_A) / 500
p_B = sum(grupo_B) / 500
diff = abs(p_A - p_B)
if diff >= diferencia:
    diferencias_extremas += 1
probabilidad_azar = diferencias_extremas / simulaciones
print(f"Simulaciones: {simulaciones}")
print(f"Diferencias >= observada: {diferencias_extremas}")
print(f"Probabilidad de que sea azar: {probabilidad_azar:.6f}")
print(f"Equivale a 1 en {1/probabilidad_azar:.0f} aproximadamente")

```

Resultado:

```

Simulaciones: 10000
Diferencias >= observada: 0
Probabilidad de que sea azar: 0.000000
Equivale a 1 en infinito aproximadamente

```

—En 10,000 simulaciones —dijo Valeria—, nunca vimos una diferencia tan grande por puro azar. La probabilidad es esencialmente cero. Esto no fue un accidente estadístico.

—¿Qué significa?

—Significa que estos datos fueron manipulados. Alguien alteró los resultados del ensayo para que el tratamiento A pareciera milagroso. Y Kamila lo descubrió.

La regla de la multiplicación

—Pero hay más —dijo Valeria—. Kamila también me enseñó sobre la probabilidad de eventos independientes.

—Por ejemplo, si la probabilidad de que una persona tenga una enfermedad es del 10% y la probabilidad de que un examen dé un falso positivo es del 5%, la probabilidad de que ambas cosas ocurran es:

$$P(A \cap B) = P(A) \times P(B) = 0.10 \times 0.05 = 0.005$$

—En términos simples, si tienes dos eventos independientes, la probabilidad de que ambos ocurran es el producto de sus probabilidades.

Valeria escribió:

```

# Probabilidad de eventos independientes
p_enfermedad = 0.10
p_falso_positivo = 0.05
p_ambos = p_enfermedad * p_falso_positivo
print(f"P(enfermedad) = {p_enfermedad}")
print(f"P(falso positivo) = {p_falso_positivo}")
print(f"P(ambos) = {p_ambos}")
print(f"0 1 en {1/p_ambos:.0f}")

```

Resultado:

```

P(enfermedad) = 0.10
P(falso positivo) = 0.05
P(ambos) = 0.005
0 1 en 200

```

—Ahora, aplica esto al caso —dijo Valeria—. Si la probabilidad de que una persona específica estuviera en el ICD a las 3 a.m. es de 0.01 (1%), y la probabilidad de que esa persona tuviera acceso al laboratorio de Kamila es de 0.10 (10%), ¿cuál es la probabilidad de que ambas condiciones se cumplan?

```

p_estar_en_icd = 0.01
p_tener_acceso = 0.10
p_ambas_condiciones = p_estar_en_icd * p_tener_acceso
print(f"Probabilidad de que una persona cumpla ambas: {p_ambas_condiciones:.4f}")
print(f"0 1 en {1/p_ambas_condiciones:.0f}")

```

—Las probabilidades son implacables —dijo Marco—. Alguien manipuló los datos y alguien estuvo allí esa noche. Y las dos cosas están conectadas.

Enigmas

Enigma 2.1: El dado cargado

Lanzas un dado 600 veces. Obtienes los siguientes resultados:

| Cara | Frecuencia |

|-----|-----|

| 1 | 120 |

| 2 | 115 |

| 3 | 108 |

| 4 | 95 |

| 5 | 90 |

| 6 | 72 |

1. ¿Cuál es la probabilidad teórica de cada cara?
2. Calcula la probabilidad observada de cada cara.
3. ¿Parece un dado cargado? ¿Por qué?

Enigma 2.2: Probabilidad del sospechoso

En una lista de 8 sospechosos, 3 tienen acceso al laboratorio, 4 tenían motivos para querer muerte a Kamila, y 2 cumplen ambas condiciones.

1. Si elegimos un sospechoso al azar, ¿cuál es la probabilidad de que tenga acceso al laboratorio?
2. ¿Cuál es la probabilidad de que tenga motivo?
3. ¿Cuál es la probabilidad de que tenga ambos?

Enigma 2.3: Simulación de la moneda

Escribe un programa en Python que simule 10,000 lanzamientos de una moneda y calcule la probabilidad estimada de obtener cara. ¿Qué tan cerca está del valor teórico de 0.5?

Lo que aprendiste

- La probabilidad mide la posibilidad de que ocurra un evento (0 a 1)
- Regla de Laplace: $P = \text{casos favorables} / \text{casos posibles}$
- Ley de los grandes números: más repeticiones → estimaciones más precisas
- Eventos independientes: $P(A \text{ y } B) = P(A) \times P(B)$
- La simulación permite estimar probabilidades mediante repetición
- Una probabilidad extremadamente baja sugiere manipulación

Valeria guardó el análisis. Fuera, la noche había caído completamente sobre Barcelona.

—Hay alguien con quien necesito hablar —dijo Valeria—. El director del ICD. Si alguien sabía lo que Kamila estaba investigando, es él.

—No creo que sea buena idea —dijo Marco—. El director... es mi padre.

Valeria lo miró fijamente.

—Tu apellido es Tupac. El director es el Dr. Hugo Tupac.

Marco asintió.
—Y no tengo idea si él está involucrado. Pero tengo miedo de averiguarlo.

Capítulo 3: El Teorema del Sospechoso

Conceptos: Probabilidad condicional, Teorema de Bayes

Valeria no durmió bien esa noche. Las palabras de Marco resonaban en su cabeza: "El director es mi padre."
¿Podía confiar en él? ¿O Marco era parte de algo más grande?

A las 7 a.m. estaba de vuelta en el ICD. Había recibido un mensaje de Marco: "Ven al laboratorio 3. Tengo algo."

Cuando llegó, Marco estaba frente a una pizarra blanca llena de números.

—Anoche no pude dormir —dijo Marco—. Estuve pensando en lo que me dijiste sobre las probabilidades. Y recordé algo que Kamila me explicó una vez: el Teorema de Bayes.

—¿Sabes lo que es?

—Sé que es una forma de actualizar nuestras creencias cuando tenemos nueva información. Pero no sé cómo aplicarlo aquí.

Valeria sonrió. Kamila le había enseñado Bayes en su primer semestre de la maestría.

—El Teorema de Bayes es la base de todo el razonamiento estadístico moderno. Nos permite calcular la probabilidad de una hipótesis dado lo que observamos.

$$P(H|E) = \frac{P(E|H) \times P(H)}{P(E)}$$

Donde:

- $P(H|E)$: probabilidad de la hipótesis dados los datos observados
- $P(E|H)$: probabilidad de observar los datos si la hipótesis es cierta
- $P(H)$: probabilidad inicial de la hipótesis
- $P(E)$: probabilidad de observar los datos

—Vamos a aplicarlo al caso —dijo Valeria—. Tenemos cuatro sospechosos principales: Ramiro Quispe (seguridad), Hugo Tupac (director), la asistente de Kamila (Sofía), y un desconocido.

Bayes aplicado al caso

Valeria abrió su laptop:

```
# Teorema de Bayes aplicado al caso
# Probabilidades iniciales (sin ninguna evidencia)
# P(H): probabilidad de que cada sospechoso sea culpable
sospechosos = ['Ramiro', 'Hugo', 'Sofia', 'Desconocido']
prob_inicial = [0.25, 0.25, 0.25, 0.25] # Todos igualmente probables
print("Probabilidades iniciales (previas):")
for s, p in zip(sospechosos, prob_inicial):
    print(f"  {s}: {p:.2f}")
```

—Pero ahora tenemos nueva información. Sabemos que:

1. Kamila fue asesinada entre las 2 a.m. y las 4 a.m.
2. La puerta estaba cerrada por dentro (posible suicidio simulado)
3. Solo personas con acceso biométrico pudieron entrar
4. Los datos del tratamiento A fueron manipulados

—Cada pieza de información actualiza nuestras probabilidades.

```
# Nueva evidencia: acceso biométrico
```

```
# P(E|H): probabilidad de tener acceso dada la culpabilidad
# Ramiro (seguridad): 100% tiene acceso
# Hugo (director): 100% tiene acceso
# Sofía (asistente): 100% tiene acceso
# Desconocido: 10% (probabilidad baja de que un desconocido tenga acceso)
prob_acceso_dado_culpable = [1.0, 1.0, 1.0, 0.1]
prob_acceso_total = sum(
    prob_acceso_dado_culpable[i] * prob_inicial[i]
    for i in range(4)
)
print(f"\nProbabilidad total de acceso: {prob_acceso_total:.2f}")
# Aplicamos Bayes:  $P(H|E) = P(E|H) * P(H) / P(E)$ 
prob_posterior_acceso = []
for i in range(4):
    posterior = (prob_acceso_dado_culpable[i] * prob_inicial[i]) / prob_acceso_total
    prob_posterior_acceso.append(posterior)
print("\nProbabilidades actualizadas (acceso biométrico):")
for s, p in zip(sospechosos, prob_posterior_acceso):
    print(f" {s}: {p:.3f}")
```

Resultado:

```
Probabilidad total de acceso: 0.775
Probabilidades actualizadas (acceso biométrico):
Ramiro: 0.323
Hugo: 0.323
Sofia: 0.323
Desconocido: 0.032
```

—El desconocido pasa de 0.25 a 0.03 —dijo Marco—. Tiene sentido: si no tenía acceso, es muy poco probable que sea el asesino.

—Exacto. Pero aún no hemos terminado. Tenemos más evidencia.

```
# Nueva evidencia: manipulación de datos
# P(E|H): probabilidad de que el sospechoso haya manipulado datos
# Ramiro (seguridad): 0.3 (podría, pero no es su área)
# Hugo (director): 0.7 (tiene acceso a todo)
# Sofía (asistente): 0.8 (trabajaba directamente con los datos)
# Desconocido: 0.2
prob_manipula_dado_culpable = [0.3, 0.7, 0.8, 0.2]
# Usamos las probabilidades anteriores como nuevas previas
prob_previas = prob_posterior_acceso
prob_manipula_total = sum(
    prob_manipula_dado_culpable[i] * prob_previas[i]
    for i in range(4)
)
prob_posterior_manipula = []
for i in range(4):
    posterior = (prob_manipula_dado_culpable[i] * prob_previas[i]) / prob_manipula_total
    prob_posterior_manipula.append(posterior)
print("\nProbabilidades actualizadas (acceso + manipulación):")
for s, p in zip(sospechosos, prob_posterior_manipula):
    print(f" {s}: {p:.3f}")
```

Resultado:

```
Probabilidades actualizadas (acceso + manipulación):
Ramiro: 0.149
Hugo: 0.348
Sofia: 0.398
Desconocido: 0.010
```

—Sofía y Hugo subieron —observó Marco—. Ramiro bajó.

—Correcto. Pero aún tenemos más evidencia: la desaparición de Ramiro.

```
# Nueva evidencia: Ramiro desapareció
# P(E|H): probabilidad de desaparecer si eres culpable
# Ramiro: 0.9 (desapareció, muy sospechoso)
```

```
# Hugo: 0.1 (sigue aquí)
# Sofia: 0.1 (sigue aquí)
# Desconocido: 0.5 (no sabemos)
prob_desaparece_dado_culpable = [0.9, 0.1, 0.1, 0.5]
prob_previas = prob_posterior_manipula
prob_desaparece_total = sum(
    prob_desaparece_dado_culpable[i] * prob_previas[i]
    for i in range(4)
)
prob_posterior_final = []
for i in range(4):
    posterior = (prob_desaparece_dado_culpable[i] * prob_previas[i]) / prob_desaparece_total
    prob_posterior_final.append(posterior)
print("\n=== PROBABILIDADES FINALES (Bayes) ===")
for s, p in sorted(zip(sospechosos, prob_posterior_final), key=lambda x: -x[1]):
    print(f"  {s}: {p:.3f} ({p*100:.1f}%")
```

Resultado:

```
=== PROBABILIDADES FINALES (Bayes) ===
Ramiro: 0.592 (59.2%)
Hugo: 0.154 (15.4%)
Sofia: 0.176 (17.6%)
Desconocido: 0.022 (2.2%)
```

—Increíble —dijo Marco—. Ramiro tiene casi 60% de probabilidad de ser el culpable, solo porque desapareció. Pero Sofía y Hugo aún tienen ~15% cada uno. No podemos descartarlos.

—Esa es la magia de Bayes —dijo Valeria—. Nunca te da una certeza absoluta, pero te dice dónde enfocar tus recursos. Y en este caso, Ramiro es nuestra mejor pista.

Más allá de las probabilidades

—Pero hay otra forma de aplicar Bayes —continuó Valeria—. Una que Kamila usaba todo el tiempo para detectar fraudes: calcular la probabilidad de que un resultado sea genuino.

—¿Cómo?

—Imagina que una prueba de detección de mentiras tiene una precisión del 95%. Si una persona es culpable, la prueba lo detecta el 95% de las veces (verdadero positivo). Si es inocente, la prueba dice que es inocente el 95% de las veces (verdadero negativo).

—Parece buena.

—Pero aquí está el truco. Si la probabilidad base de culpabilidad en la población es del 1%, y la prueba dice que alguien es culpable, ¿cuál es la probabilidad real de que sea culpable?

Valeria escribió:

```
# Paradoja de la prueba
p_culpable = 0.01 # 1% de la población
p_inocente = 0.99
precision_prueba = 0.95 # 95% de precisión
# P(positivo | culpable) = 0.95
# P(positivo | inocente) = 0.05 (falso positivo)
p_positivo = (0.95 * 0.01) + (0.05 * 0.99)
p_culpable_dado_positivo = (0.95 * 0.01) / p_positivo
print(f"P(culpable | prueba positiva) = {p_culpable_dado_positivo:.3f}")
print(f"O solo {p_culpable_dado_positivo*100:.1f}%")
```

Resultado:

```
P(culpable | prueba positiva) = 0.161
O solo 16.1%
}
```

—¿Solo 16%? —preguntó Marco—. Pero la prueba tiene 95% de precisión.

—Exacto. Por eso Bayes es tan importante. Cuando la condición es rara (1 de cada 100 es culpable), incluso una prueba pr
—Eso cambia todo.

—Y es exactamente por eso que Kamila usaba Bayes para todo. Para detectar fraudes, para analizar datos clínicos, para en Marco se quedó en silencio un momento.

—Entonces —dijo—, si Ramiro tiene 59% de probabilidad según Bayes, y sabiendo que la probabilidad base de que una person —Casi seguro no existe en estadística —sonrió Valeria—. Pero sí, es nuestra mejor apuesta.

—Entonces tenemos que encontrarlo.

—No. Primero tenemos que entender por qué manipuló los datos. Y para eso, necesito ver algo más.

—¿Qué?

—Las distribuciones reales de los datos antes de la manipulación. Si Kamila encontró el fraude, seguro guardó una copia

Enigmas

Enigma 3.1: Bayes con tus datos

Un detector de fraudes financieros tiene una precisión del 99%. Si el 0.5% de las transacciones son fraudulentas, y el d

Enigma 3.2: El test médico

Una enfermedad afecta al 2% de la población. Un test la detecta con un 98% de precisión. Si una persona da positivo:

1. ¿Cuál es la probabilidad de que realmente tenga la enfermedad?
2. ¿Por qué es tan baja a pesar de la alta precisión?

Enigma 3.3: Bayes en cadena

Usando los datos del capítulo, agrega una nueva evidencia: las cámaras de seguridad muestran a alguien de baja estatura

- Ramiro: 1.75m $\rightarrow P(\text{baja estatura} \mid \text{culpable}) = 0.05$
- Hugo: 1.82m $\rightarrow P(\text{baja estatura} \mid \text{culpable}) = 0.05$
- Sofía: 1.55m $\rightarrow P(\text{baja estatura} \mid \text{culpable}) = 0.80$
- Desconocido: $P(\text{baja estatura} \mid \text{culpable}) = 0.50$

Actualiza las probabilidades de los sospechosos. ¿Quién sube? ¿Quién baja?

Lo que aprendiste

- El **Teorema de Bayes** actualiza probabilidades con nueva información
- Las **probabilidades condicionales** miden la probabilidad de un evento dado otro
- **$P(E|H)$** : probabilidad de la evidencia si la hipótesis es cierta
- La **paradoja de la prueba**: pruebas precisas pueden ser engañosas con condiciones raras
- Bayes es fundamental para el razonamiento estadístico y la detección de fraudes

—Vamos a buscar esos datos originales —dijo Valeria—. Pero primero, necesito que me lleves al despacho de tu padre. Marco dudó.

—¿Estás segura?

—Si Hugo Tupac es inocente, nos ayudará. Si es culpable, necesito ver su reacción cuando le pregunte por los datos. Marco asintió.

—Vamos.

Capítulo 4: La Distribución del Engaño

Conceptos: Distribución normal, desviación estándar, Z-score, regla empírica

El despacho del Dr. Hugo Tupac ocupaba todo el octavo piso del ICD. Paredes de vidrio, muebles de madera tallada a mano,

—Siéntense —dijo sin levantar la vista de su computadora—. Sabía que vendrían.

—¿Sabía? —preguntó Valeria.

—Marco es mi hijo. Y Kamila era mi mejor investigadora. Cuando alguien muere en tu institución, las preguntas no tardan El Dr. Tupac finalmente levantó la vista.

—¿Qué quieren saber?

—Todo —dijo Valeria—. ¿Qué estaba investigando Kamila?

—No lo sé con exactitud. Ella trabajaba en el proyecto Yupay, un sistema de modelos predictivos. Pero en las últimas sem

—¿Qué tipo de anomalía?

—No me dio detalles. Dijo que necesitaba verificarlo antes de hablarlo con alguien.

—¿Y usted no preguntó?

—Pregunté. Me dijo que esperara. Y luego... apareció muerta.

Valeria observó al director. Su lenguaje corporal era abierto, sus respuestas directas. Pero algo no encajaba.

—Necesito acceso a los datos del proyecto Yupay —dijo Valeria.

—Imposible. Son datos clasificados del ministerio.

—Entonces deme acceso a los servidores donde Kamila guardaba sus copias de seguridad.

El Dr. Tupac la miró largamente.

—Una hora. Marco te acompañará. Y si encuentras algo, me lo reportas directamente.

Salieron del despacho. Marco estaba pálido.

—¿Crees que dice la verdad? —preguntó.

—No lo sé —respondió Valeria—. Pero sus respuestas fueron... estadísticamente normales. Sin desviaciones. Y eso, a veces

La distribución normal

En la sala de servidores, Valeria encontró los backups de Kamila. Había docenas de archivos, pero uno llamó su atención:

—Esto es un archivo NumPy —dijo—. Contiene datos numéricos puros.

Lo cargó en Python:

```
import numpy as np
import matplotlib.pyplot as plt
```

Cargamos los datos originales

```
datos_originales = np.load('distribucion_original.npy')
print(f"Shape: {datos_originales.shape}")
print(f"Tipo: {datos_originales.dtype}")
print(f"Primeros 20 valores: {datos_originales[:20]}")
```

Resultado:

```
Shape: (10000,)
Tipo: float64
Primeros 20 valores: [72.3 68.1 74.5 71.2 69.8 73.0 70.5 75.1 67.9 72.8
70.2 74.0 71.8 69.5 73.4 68.7 72.1 70.9 75.3 71.5]
}
```

—Son mediciones de presión arterial —dijo Valeria—. De un estudio clínico. Vamos a ver su distribución.

```
# Visualizar la distribución
media = np.mean(datos_originales)
mediana = np.median(datos_originales)
desv_std = np.std(datos_originales)
print(f"Media: {media:.2f}")
print(f"Mediana: {mediana:.2f}")
print(f"Desviación estándar: {desv_std:.2f}")
print(f"Mínimo: {np.min(datos_originales):.2f}")
print(f"Máximo: {np.max(datos_originales):.2f}")

# Histograma
plt.hist(datos_originales, bins=50, alpha=0.7, color='blue', edgecolor='black')
plt.axvline(media, color='red', linestyle='--', label=f'Media = {media:.1f}')
plt.axvline(media - desv_std, color='green', linestyle=':', label=f'-1σ')
plt.axvline(media + desv_std, color='green', linestyle=':', label=f'+1σ')
plt.title('Distribución de Presión Arterial (Datos Originales)')
plt.xlabel('Presión Arterial')
plt.ylabel('Frecuencia')
plt.legend()
plt.show()
```

—Mira esto —dijo Valeria señalando la pantalla—. La distribución tiene forma de campana. Es una distribución normal (o gaussiana).

—¿Por qué es importante?

—Porque en una distribución normal, hay una regla empírica que se cumple siempre:

- El 68% de los datos está a 1 desviación estándar de la media
- El 95% está a 2 desviaciones estándar
- El 99.7% está a 3 desviaciones estándar

```
# Verificar la regla empírica
dentro_1sigma = np.sum(np.abs(datos_originales - media) <= desv_std)
dentro_2sigma = np.sum(np.abs(datos_originales - media) <= 2 * desv_std)
dentro_3sigma = np.sum(np.abs(datos_originales - media) <= 3 * desv_std)
total = len(datos_originales)
print(f"\n=== REGLA EMPÍRICA ===")
print(f"68% teórico: 6800")
print(f"Dentro de 1σ: {dentro_1sigma} ({100*dentro_1sigma/total:.1f}%)")
print(f"95% teórico: 9500")
print(f"Dentro de 2σ: {dentro_2sigma} ({100*dentro_2sigma/total:.1f}%)")
print(f"99.7% teórico: 9970")
```

```
print(f"Dentro de 3σ: {dentro_3sigma} ({100*dentro_3sigma/total:.1f}%)")
```

Resultado:

```
=== REGLA EMPÍRICA ===
68% teórico: 6800
Dentro de 1σ: 6832 (68.3%)
95% teórico: 9500
Dentro de 2σ: 9495 (95.0%)
99.7% teórico: 9970
Dentro de 3σ: 9973 (99.7%)
}
-Casi perfecto -dijo Valeria-. Estos datos son genuinos. Ahora comparemos con los datos manipulados que vimos en el capí
---
## El Z-score: midiendo la anomalía
-El **Z-score** nos dice a cuántas desviaciones estándar está un valor de la media. Es la forma estándar de identificar

$$Z = \frac{x - \mu}{\sigma}$$

Valeria escribió:
```

Calcular Z-scores para identificar anomalías

```
def z_score(valor, media, desv_std):
    return (valor - media) / desv_std
```

Encontremos los valores más extremos

```
z_scores = np.abs((datos_originales - media) / desv_std)
indices_extremos = np.argsort(z_scores)[-5:] # 5 valores más extremos
print(f"\n=== VALORES EXTREMOS (Z-score) ===")
print(f"{'Índice':<10} {'Valor':<12} {'Z-score':<10}")
print("-" 32)
for i in indices_extremos:
    z = z_score(datos_originales[i], media, desv_std)
    print(f"{'i':<10} {'datos_originales[i]:<12.2f} {'z:<10.2f}")
```

¿Cuántos valores tienen Z-score > 3?

```
extremos = np.sum(z_scores > 3)
print(f"\nValores con Z-score > 3: {extremos}")
print(f"Esperado (0.3%): {int(0.003 * len(datos_originales))}")
```

Resultado:

```
=== VALORES EXTREMOS (Z-score) ===
Índice   Valor   Z-score

3412     65.2   -2.98
8911     76.8    2.95
4523     64.9   -3.12
1023     77.1    3.05
7845     63.8   -3.41

Valores con Z-score > 3: 27
Esperado (0.3%): 30
}
```


—Ahora —dijo Valeria—, comparemos con los datos falsos del ensayo clínico.

Valeria cargó los datos del capítulo anterior.

```
# Datos falsos: 500 pacientes, 470 mejoran (tratamiento A)
# Bajo una distribución normal, esperaríamos cierta variabilidad
# Simulamos cómo deberían verse datos genuinos
import random
random.seed(42)
datos_genuinos = []
for _ in range(500):
    if random.random() < 0.71: # 71% de mejora general
        datos_genuinos.append(1) # mejora
    else:
        datos_genuinos.append(0) # no mejora
tasa_genuina = sum(datos_genuinos) / 500
# Simulamos 10000 ensayos para ver la distribución esperada
tasas_simuladas = []
for _ in range(10000):
    ensayo = []
    for _ in range(500):
        if random.random() < 0.71:
            ensayo.append(1)
        else:
            ensayo.append(0)
    tasas_simuladas.append(sum(ensayo) / 500)
media_simulada = np.mean(tasas_simuladas)
std_simulada = np.std(tasas_simuladas)
print(f"Media de tasas simuladas: {media_simulada:.3f}")
print(f"Desviación estándar: {std_simulada:.3f}")
# ¿Qué tan extrema es la tasa observada del tratamiento A (94%)?
tasa_observada = 0.94
z_tasa = (tasa_observada - media_simulada) / std_simulada
print(f"\nTasa observada (Tratamiento A): {tasa_observada}")
print(f"Z-score de la tasa observada: {z_tasa:.2f}")
print(f"Esto es {z_tasa:.0f} desviaciones estándar por encima de la media")
print(f"Probabilidad de ocurrir al azar: esencialmente 0")
```

Resultado:

```
Media de tasas simuladas: 0.710
Desviación estándar: 0.020
Tasa observada (Tratamiento A): 0.94
Z-score de la tasa observada: 11.50
Esto es 12 desviaciones estándar por encima de la media
Probabilidad de ocurrir al azar: esencialmente 0
}
—Un Z-score de 11.5 —dijo Valeria—. En el mundo real, un Z-score mayor a 3 ya es extremadamente raro. Once punto cinco e
—Alguien manipuló estos números —dijo Marco.
—Sí. Y quien lo hizo no entiende de distribuciones normales. Porque si supiera, habría hecho que los datos falsos se vie
---
## La distribución del engaño
Valeria abrió otro archivo del backup de Kamila.
—Mira esto. Kamila guardó una comparación entre los datos originales y los datos manipulados.
```

Comparación visual

```
datos_manipulados = np.load('datos_manipulados.npy')
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 5))
ax1.hist(datos_originales, bins=50, alpha=0.7, color='blue')
ax1.set_title('Datos Originales')
ax1.set_xlabel('Presión Arterial')
ax2.hist(datos_manipulados, bins=50, alpha=0.7, color='red')
```

```
ax2.set_title('Datos Manipulados')
ax2.set_xlabel('Presión Arterial')
plt.tight_layout()
plt.show()
```

Estadísticas comparativas

```
print(f'{"Métrica":<25} {"Original":<12} {"Manipulado":<12}')
```

```
print("-" 49)
```

```
print(f'{"Media":<25} {np.mean(datos_originales):<12.2f} {np.mean(datos_manipulados):<12.2f}')
```

```
print(f'{"Desviación Std":<25} {np.std(datos_originales):<12.2f} {np.std(datos_manipulados):<12.2f}')
```

```
print(f'{"Mediana":<25} {np.median(datos_originales):<12.2f} {np.median(datos_manipulados):<12.2f}')
```

```
print(f'{"Asimetría (skewness)":<25} {np.mean((((datos_originales - np.mean(datos_originales))/np.std(datos_originales))3):<12.2f} {np.mean((((datos_manipulados - np.mean(datos_manipulados))/np.std(datos_manipulados))3):<12.2f}')
```

Resultado:

Métrica	Original	Manipulado
Media	71.23	74.56
Desviación Std	2.11	0.95
Mediana	71.20	74.50
Asimetría (skewness)	0.02	0.85

—¿Ves la diferencia? —preguntó Valeria—. Los datos originales tienen una desviación estándar de 2.11, los manipulados de solo 0.95. La desviación estándar se redujo a la mitad. Y la asimetría pasó de casi cero (normal) a 0.85 (sesgada).

—¿Qué significa eso?

—Que alguien no solo cambió los valores, sino que alteró la variabilidad natural de los datos. Los datos falsos son demasiado perfectos. Demasiado centrados. En estadística, eso se llama un sesgo de manipulación.

Enigmas

Enigma 4.1: Identifica los outliers

Un conjunto de edades tiene media 45 y desviación estándar 10. Calcula los Z-scores de las siguientes edades e identifica cuáles son outliers ($|Z| > 3$):

[23, 45, 67, 72, 18, 81, 44, 46, 22, 78]

Enigma 4.2: La regla empírica

En una distribución normal con media 100 y desviación estándar 15:

1. ¿Qué porcentaje de valores está entre 85 y 115?
2. ¿Entre 70 y 130?
3. ¿Entre 55 y 145?

Enigma 4.3: Detecta la manipulación

Te dan dos conjuntos de datos. Uno es genuino y el otro fue manipulado. Calcula la media, desviación estándar y Z-scores de ambos. ¿Cuál parece manipulado y por qué?

```
conjunto_A = [72, 68, 74, 71, 69, 73, 70, 75, 67, 72, 70, 74, 71, 69, 73]
```

```
conjunto_B = [72, 72, 73, 71, 72, 72, 72, 71, 73, 72, 72, 73, 71, 72, 72]
```

Lo que aprendiste

- La distribución normal (campana de Gauss) es la distribución más común en la naturaleza
- La regla empírica: 68-95-99.7% de los datos dentro de 1-2-3 desviaciones estándar
- El Z-score mide cuán atípico es un valor: $Z = (x - \mu) / \sigma$
- $|Z| > 3$ generalmente indica un outlier
- Datos manipulados suelen tener menor variabilidad y mayor asimetría

Valeria cerró su laptop.

—Tengo suficiente para demostrar que los datos del ensayo fueron manipulados. Pero aún no sé quién lo hizo ni por qué.

—¿Y ahora? —preguntó Marco.

—Ahora vamos a buscar a Ramiro. Porque si él no manipuló los datos, alguien lo está usando como chivo expiatorio. Y si él lo hizo... necesito saber por qué.

Marco asintió.

—Tengo una idea de dónde puede estar.

Capítulo 5: La Muestra que Miente

Conceptos: Población vs muestra, sesgo de selección, muestreo, tipos de muestreo

Marco llevó a Valeria a un mercado en el barrio de San Pedro. Entre puestos de frutas, especias y artesanías, había un pequeño local de tecnología con un cartel que decía "REPARACIONES RÁPIDAS — COMPRA Y VENTA DE LAPTOPS".

—Aquí —dijo Marco—. Ramiro viene aquí. Su hermano es dueño del local.

Entraron. El local era oscuro, lleno de computadoras viejas y cables por todos lados. Detrás del mostrador, un hombre delgado y de mirada nerviosa los observó.

—¿Ramiro? —preguntó Valeria.

—No está —respondió el hombre—. Y no sé dónde está.

—Somos amigos de Kamila Huamán —dijo Marco—. Necesitamos hablar con él antes de que sea demasiado tarde.

El hombre dudó. Luego señaló una puerta al fondo.

—Segundo piso. Pero no le digan que yo los envié.

Subieron las escaleras. La puerta del segundo piso estaba entreabierta. Valeria la empujó suavemente.

Ramiro Quispe estaba sentado frente a una computadora, rodeado de papeles y tazas de café vacías. Cuando los vio, dio un salto.

—¿Quiénes son? ¿Qué quieren?

—Soy Valeria Quispe. Esto es Marco Tupac. Trabajamos con la doctora Huamán.

—No sé nada —dijo Ramiro—. No sé cómo murió, no sé quién la mató, no sé nada.

—No te creo —dijo Valeria—. Y si no hablas con nosotros, hablarás con la policía.

Ramiro se derrumbó.

—Está bien. Pero lo que voy a decirles... no sé si me van a creer.

La muestra que miente

—Kamila me pidió que la ayudara —dijo Ramiro—. Estaba investigando un fraude en los ensayos clínicos del Ministerio de Salud. Alguien estaba manipulando los datos para que un medicamento pareciera más efectivo de lo que realmente era.

—¿Y tú qué tenías que ver?

—Ella necesitaba acceso a los servidores del ministerio. Y yo... bueno, tengo mis contactos.

—¿Encontraste algo?

Ramiro asintió.

—Encontré los logs de acceso. Alguien entró a los servidores a las 2:30 a.m. de la noche en que Kamila murió. Y no solo entró: subió archivos y borró otros.

—¿Quién?

—No tengo nombre. Pero tengo la IP. Y las huellas digitales.

Valeria se sentó frente a la computadora de Ramiro.

—Enséñame.

—Hay un problema —dijo Ramiro—. Los logs que tengo son solo una muestra de los datos totales. El ministerio borró la mayoría. Lo que tengo es lo que alcancé a copiar antes de que me descubrieran.

—¿Qué tan grande es la muestra?

—52 registros de un total de... no sé. Podrían ser miles.

—Entonces tenemos un problema de sesgo de selección —dijo Valeria.

Población vs muestra

—En estadística —explicó Valeria—, la población es el conjunto completo de datos. La muestra es un subconjunto. La clave es que la muestra debe ser representativa de la población.

—¿Y cómo sabemos si una muestra es representativa?

—Depende del método de muestreo.

Valeria abrió Python:

```
# Tipos de muestreo en Python
import random
import numpy as np
# Población total (simulada)
poblacion = list(range(1, 10001))
print(f"Población total: {len(poblacion)}")
# 1. MUESTREO ALEATORIO SIMPLE
# Cada elemento tiene la misma probabilidad de ser seleccionado
muestra_aleatoria = random.sample(poblacion, 100)
print(f"\n1. Muestreo aleatorio simple: {len(muestra_aleatoria)} elementos")
print(f"   Primeros 10: {muestra_aleatoria[:10]}")
# 2. MUESTREO SISTEMÁTICO
# Seleccionamos cada k-ésimo elemento
k = 100 # Cada 100 elementos
muestra_sistemática = poblacion[::k]
print(f"\n2. Muestreo sistemático (k=100): {len(muestra_sistemática)} elementos")
print(f"   Elementos: {muestra_sistemática[:10]}")
# 3. MUESTREO ESTRATIFICADO
# Dividimos la población en grupos y muestreamos cada grupo
```

```
def muestreo_estratificado(poblacion, estratos, tamano_muestra):
    """estratos: diccionario con {nombre: [elementos]}"""
    muestra = []
    for estrato, elementos in estratos.items():
        n = int(len(elementos) / sum(len(e) for e in estratos.values()) * tamano_muestra)
        muestra.extend(random.sample(elementos, min(n, len(elementos))))
    return muestra

# Simulamos estratos
estratos = {
    'jovenes': list(range(1, 4001)),
    'adultos': list(range(4001, 7001)),
    'mayores': list(range(7001, 10001))
}

muestra_estratificada = muestreo_estratificado(poblacion, estratos, 300)
print(f"\n3. Muestreo estratificado: {len(muestra_estratificada)} elementos")
print(f"    Distribución: jóvenes={sum(1 for x in muestra_estratificada if x <= 4000)}, "
      f"adultos={sum(1 for x in muestra_estratificada if 4000 < x <= 7000)}, "
      f"mayores={sum(1 for x in muestra_estratificada if x > 7000)}")
```

Resultado:

```
Población total: 10000
1. Muestreo aleatorio simple: 100 elementos
   Primeros 10: [4321, 7890, 1234, 5678, 9012, 3456, 7891, 2345, 6789, 123]
2. Muestreo sistemático (k=100): 100 elementos
   Elementos: [1, 101, 201, 301, 401, 501, 601, 701, 801, 901]
3. Muestreo estratificado: 300 elementos
   Distribución: jóvenes=120, adultos=90, mayores=90
```

—Pero hay un tipo de muestreo que es peligroso para nuestra investigación —dijo Valeria—. El sesgo de selección.

```
# SESGO DE SELECCIÓN
# Ocurre cuando la muestra no es representativa de la población
# Ejemplo: encuesta de satisfacción
# Solo responden los que están muy satisfechos o muy insatisfechos
poblacion_satisfaccion = list(range(1, 1001)) # 1000 personas
satisfaccion_real = np.random.normal(7.0, 1.5, 1000) # Satisfacción real (1-10)
# Sesgo: solo responden los extremos (satisfacción < 3 o > 8)
sesgo_seleccion = [(i, s) for i, s in enumerate(satisfaccion_real) if s < 3 or s > 8]
muestra_sesgada = [s for _, s in sesgo_seleccion]
print(f"\n=== SESGO DE SELECCIÓN ===")
print(f"Media real de satisfacción: {np.mean(satisfaccion_real):.2f}")
print(f"Media de la muestra sesgada: {np.mean(muestra_sesgada):.2f}")
print(f"Diferencia: {abs(np.mean(satisfaccion_real) - np.mean(muestra_sesgada)):.2f}")
print(f"Tamaño de muestra sesgada: {len(muestra_sesgada)} de {len(satisfaccion_real)}")
```

Resultado:

```
=== SESGO DE SELECCIÓN ===
Media real de satisfacción: 7.02
Media de la muestra sesgada: 5.85
Diferencia: 1.17
}
-La muestra sesgada muestra una satisfacción de 5.85 cuando la real es 7.02. Eso es un error de 1.17 puntos. Y en el mun
---
## El problema con los logs de Ramiro
Valeria analizó los logs de acceso.
```

Analizando los logs de Ramiro

Solo tenemos 52 registros de un total desconocido

```
logs_disponibles = 52
```

```
total_estimado = 500 # Estimación
```

```
proporcion_muestra = logs_disponibles / total_estimado
print(f"Proporción de la muestra: {proporcion_muestra:.1%}")
print(f"Margen de error potencial: ±{1 / (logs_disponibles ** 0.5) * 100:.1f}%")
```

¿Qué IPs aparecen?

```
from collections import Counter

ips_en_logs = [
    '192.168.1.10', '192.168.1.20', '192.168.1.10', '10.0.0.5',
    '192.168.1.30', '192.168.1.10', '10.0.0.5', '172.16.0.1',
    '192.168.1.10', '192.168.1.20', '10.0.0.5', '172.16.0.1',
    '192.168.1.10', '10.0.0.5', '172.16.0.1'
]

conteo_ips = Counter(ips_en_logs)
print(f"\n=== IPS EN LOGS (muestra) ===")
for ip, count in conteo_ips.most_common():
    print(f" {ip}: {count} accesos ({count/len(ips_en_logs)*100:.1f}%)")
```

Resultado:

```
Proporción de la muestra: 10.4%
Margen de error potencial: ±13.9%
=== IPS EN LOGS (muestra) ===
192.168.1.10: 27 accesos (51.9%)
10.0.0.5: 8 accesos (15.4%)
172.16.0.1: 7 accesos (13.5%)
192.168.1.20: 6 accesos (11.5%)
192.168.1.30: 4 accesos (7.7%)
```

```
-La IP 192.168.1.10 aparece en el 51.9% de los accesos -dijo Valeria-. Pero esta es solo una muestra. Podría ser que est
-¿Qué hacemos entonces? -preguntó Marco.
-Necesitamos una muestra más grande. O mejor aún: necesitamos toda la población. Ramiro, ¿puedes acceder a los logs comp
-No. Me descubrieron. Mi acceso está bloqueado.
-Entonces tendremos que trabajar con lo que tenemos. Pero tenemos que ser honestos sobre las limitaciones de nuestra mue
---
## El muestreo estratificado y el caso
-Hay otro tipo de muestreo que podría ayudarnos -dijo Valeria-. El **muestreo estratificado**. Si dividimos a los sospech
```

Muestreo estratificado aplicado a los sospechosos

```
sospechosos_por_grupo = {
    'academicos': {
        'Hugo Tupac': {'acceso': True, 'motivo': 0.3, 'coartada': 0.7},
        'Sofia Vargas': {'acceso': True, 'motivo': 0.2, 'coartada': 0.5},
        'otros_investigadores': ['Luis Mamani', 'Rosa Quispe']
    },
    'seguridad': {
        'Ramiro Quispe': {'acceso': True, 'motivo': 0.5, 'coartada': 0.1},
        'guardias_nocturnos': ['Pedro Condori', 'Juan Huamán']
    }
}
```

```

},
'externos': {
'proveedor_medicamento': {'acceso': False, 'motivo': 0.8, 'coartada': 0.3},
'consultor_ministerio': {'acceso': True, 'motivo': 0.6, 'coartada': 0.4}
}
}

print("=== ANÁLISIS POR ESTRATOS ===")
for estrato, miembros in sospechosos_por_grupo.items():
print(f"\nEstrato: {estrato}")
for nombre, datos in miembros.items():
if isinstance(datos, dict):
print(f" {nombre}: acceso={datos['acceso']}, motivo={datos['motivo']}, "
f"coartada={datos['coartada']}")
else:
print(f" {nombre}")

```

Resultado:

```

=== ANÁLISIS POR ESTRATOS ===
Estrato: academicos
Hugo Tupac: acceso=True, motivo=0.3, coartada=0.7
Sofia Vargas: acceso=True, motivo=0.2, coartada=0.5
otros_investigadores: ['Luis Mamani', 'Rosa Quispe']
Estrato: seguridad
Ramiro Quispe: acceso=True, motivo=0.5, coartada=0.1
guardias_nocturnos: ['Pedro Condori', 'Juan Huamán']
Estrato: externos
proveedor_medicamento: acceso=False, motivo=0.8, coartada=0.3
consultor_ministerio: acceso=True, motivo=0.6, coartada=0.4

```

–Lo interesante –dijo Valeria señalando la pantalla– es que el **proveedor del medicamento** tiene el motivo más alto (0
–Pero los datos de Ramiro vinieron de su propia muestra –dijo Marco–. ¿Y si está manipulando su propia muestra para desv
Valeria sonrió.

–Eso, Marco, demuestra que estás aprendiendo. Porque en estadística, la primera pregunta que debes hacerte siempre es: *

Enigmas

Enigma 5.1: Identifica el sesgo

En cada escenario, identifica el tipo de sesgo de selección:

1. Una encuesta política llama solo a teléfonos fijos durante el día
2. Un estudio médico solo incluye voluntarios jóvenes y sanos
3. Una encuesta de satisfacción solo la responden los clientes más molestos o más contentos
4. Un estudio sobre ingresos solo usa datos de personas que declaran impuestos

Enigma 5.2: Calcula el error muestral

Tienes una muestra de 400 personas de una población de 10,000. Quieres estimar la proporción de personas que prefieren u

1. ¿Cuál es el margen de error?
(Fórmula: $ME = \frac{1}{\sqrt{n}}$, donde n es el tamaño de la muestra)
2. ¿Entre qué valores está la proporción real con 95% de confianza?

Enigma 5.3: Diseña un muestreo

Tienes que investigar la satisfacción de los estudiantes de una universidad con 5 facultades. ¿Qué tipo de muestreo usar

Lo que aprendiste

- La **población** es el conjunto completo de datos; la **muestra** es un subconjunto
- El **muestreo aleatorio simple** da la misma probabilidad a cada elemento

```

- El muestreo estratificado divide la población en grupos y muestrea cada uno
- El sesgo de selección ocurre cuando la muestra no es representativa
- El margen de error disminuye con el tamaño de la muestra
- Siempre pregunta: ¿quién recolectó esta muestra y qué interés tiene?
-Necesito una muestra más grande -dijo Valeria-. Y sé exactamente dónde conseguirla.
-¿Dónde? -preguntaron Marco y Ramiro al unísono.
-En el servidor del ministerio. Si no podemos entrar por la puerta principal, entraremos por la ventana.
Ramiro la miró con preocupación.
-Eso es ilegal.
-La muerte de Kamila también lo fue. A veces, la estadística no es suficiente. A veces hay que ensuciarse las manos.
-Te ayudo -dijo Ramiro-. Pero si nos descubren, no me conocen.
-Trato hecho.

# Capítulo 6: La Hipótesis Asesina
## Conceptos: Prueba de hipótesis, hipótesis nula y alternativa, valor p, significancia estadística
---
```

Ramiro trabajó toda la noche. Cuando Valeria y Marco llegaron al local de reparaciones a la mañana siguiente, lo encontraron.

¿Lo lograste? -preguntó Valeria.

Ramiro levantó la cabeza lentamente, con los ojos rojos.

-Sí. Pero no me gusta lo que encontré.

¿Qué es?

-Los logs completos del ministerio. 5,000 registros. Y una IP que aparece repetidamente en los momentos clave.

¿Cuál IP?

-172.16.0.1. Es la IP del ICD. Del servidor interno.

¿Del ICD? -preguntó Marco-. ¿Alguien dentro del ICD accedió a los datos del ministerio?

-No solo accedió -dijo Ramiro-. Modificó archivos. Borró registros. Y todo ocurrió entre las 2 y las 4 a.m. de la noche.

¿Puedes identificar al usuario?

-No. La conexión usaba credenciales genéricas. Pero hay algo más.

¿Qué?

-La IP 172.16.0.1 es la del despacho del director.

El silencio se instaló en la habitación. Marco palideció.

-Mi padre -dijo en voz baja.

-O alguien que usó su computadora -corrigió Valeria-. Aún no tenemos pruebas suficientes.

¿Cómo vamos a obtenerlas?

-Con una **prueba de hipótesis**.

La hipótesis nula y la alternativa

-En estadística -explicó Valeria-, cuando queremos probar algo, formulamos dos hipótesis:

- Hipótesis nula (H_0)**: lo que asumimos que es verdad por defecto. "No hay efecto", "no hay diferencia", "todo es normal".
- Hipótesis alternativa (H_1)**: lo que queremos demostrar. "Hay un efecto", "hay una diferencia", "algo está mal".

-En nuestro caso:

- H_0** : El Dr. Hugo Tupac no accedió a los datos del ministerio esa noche
- H_1** : El Dr. Hugo Tupac accedió a los datos del ministerio esa noche

-Pero no podemos probar H_1 directamente. Lo que hacemos es tratar de **rechazar H_0** . Si los datos son suficientemente inconsistentes.

¿Y cómo sabemos si los datos son "suficientemente inconsistentes"?

-Con el **valor p** (p-value).

El valor p

Valeria abrió Python:

Prueba de hipótesis aplicada al caso

```
import numpy as np
import random
```

DATOS DEL CASO

Queremos saber si Hugo Tupac es responsable de los accesos nocturnos

Paso 1: Definir las hipótesis


```
print("=== PRUEBA DE HIPÓTESIS ===")
print("H: Hugo Tupac NO accedió a los datos")
print("H: Hugo Tupac SÍ accedió a los datos")
print()
```

Paso 2: Recopilar evidencia

Logs de acceso: 5000 registros

Accesos desde la IP del despacho de Hugo: 78 (de 5000)

Accesos nocturnos (2-4 a.m.) desde cualquier IP: 12

Accesos nocturnos desde la IP de Hugo: 5

```
total_accesos = 5000
accesos_ip_hugo = 78
accesos_nocturnos = 12
accesos_nocturnos_hugo = 5
print(f"Total de accesos en logs: {total_accesos}")
print(f"Accesos desde IP de Hugo: {accesos_ip_hugo}")
print(f"Accesos nocturnos (2-4 a.m.): {accesos_nocturnos}")
print(f"Accesos nocturnos desde IP de Hugo: {accesos_nocturnos_hugo}")
print()
```

Paso 3: Calcular la probabilidad esperada bajo H

Si Hugo es inocente, los accesos nocturnos desde su IP deberían seguir

la misma distribución que el resto de accesos

```
proporcion_ip_hugo = accesos_ip_hugo / total_accesos
print(f"Proporción de accesos desde IP de Hugo: {proporcion_ip_hugo:.4f}")
print(f"Esperados (si H es cierta): {proporcion_ip_hugo * accesos_nocturnos:.2f} accesos nocturnos")
print(f"Observados: {accesos_nocturnos_hugo}")
print()
```

Paso 4: Simular para obtener el valor p

Bajo H, simulamos 10000 escenarios y vemos con

qué frecuencia

obtenemos 5 o más accesos nocturnos desde la IP de Hugo

```
random.seed(42)
simulaciones = 100000
resultados_extremos = 0
for _ in range(simulaciones):
```

Simulamos los 12 accesos nocturnos

```
    accesos_simulados = []
    for _ in range(accesos_nocturnos):
        if random.random() < proporcion_ip_hugo:
            accesos_simulados.append('hugo')
        else:
            accesos_simulados.append('otro')
    conteo_hugo = sum(1 for a in accesos_simulados if a == 'hugo')
    if conteo_hugo >= accesos_nocturnos_hugo:
        resultados_extremos += 1
    p_valor = resultados_extremos / simulaciones
    print(f"=== VALOR P ===")
    print(f"Simulaciones: {simulaciones}")
    print(f"Resultados extremos (>= {accesos_nocturnos_hugo}): {resultados_extremos}")
    print(f"Valor p: {p_valor:.6f}")
    print(f"Interpretación: {'RECHAZAMOS H' if p_valor < 0.05 else 'NO RECHAZAMOS H'})")
```

Resultado:

```
=== PRUEBA DE HIPÓTESIS ===
H: Hugo Tupac NO accedió a los datos
H: Hugo Tupac SÍ accedió a los datos
Total de accesos en logs: 5000
Accesos desde IP de Hugo: 78
Accesos nocturnos (2-4 a.m.): 12
Accesos nocturnos desde IP de Hugo: 5
Proporción de accesos desde IP de Hugo: 0.0156
Esperados (si H es cierta): 0.19 accesos nocturnos
Observados: 5
=== VALOR P ===
Simulaciones: 100000
Resultados extremos (>= 5): 0
```

Valor p: 0.000000

Interpretación: RECHAZAMOS H

```
-El valor p es esencialmente 0 -dijo Valeria-. La probabilidad de haber observado 5 accesos nocturnos desde la IP de Hug
-Eso significa... -Marco no podía terminar la frase.
-Significa que los datos apuntan a tu padre. Pero estadísticamente, esto no es una condena. Es una **evidencia**. Necesitamos
---
## La significancia estadística y los errores
-En las pruebas de hipótesis, hay dos errores posibles:
```

```
print("=== ERRORES EN PRUEBAS DE HIPÓTESIS ===")
print()
print("ERROR TIPO I (Falso Positivo): Rechazar H cuando es verdadera")
print(" → Decir que Hugo es culpable cuando es inocente")
print(" → Probabilidad =  $\alpha$  (nivel de significancia, típicamente 0.05)")
print()
print("ERROR TIPO II (Falso Negativo): No rechazar H cuando es falsa")
print(" → Decir que Hugo es inocente cuando es culpable")
print(" → Probabilidad =  $\beta$ ")
print()
print(f"Nuestro valor p ({p_valor:.6f}) es menor que  $\alpha$  (0.05)")
print(f"→ Rechazamos H con 95% de confianza")
print(f"→ Pero hay 5% de probabilidad de que esto sea un falso positivo")
```

```
-Entonces, ¿hay un 5% de probabilidad de que mi padre sea inocente? -preguntó Marco.
-Si solo nos basáramos en esta prueba, sí. Pero la evidencia no termina aquí. Cuantas más pruebas independientes tengamos
---
## La fuerza de la evidencia
Valeria continuó:
-En estadística, una prueba sola rara vez es concluyente. Pero cuando múltiples pruebas apuntan en la misma dirección, la
```

Múltiples pruebas de hipótesis

```
print("=== MÚLTIPLES EVIDENCIAS ===")
print()
```

Evidencia 1: Accesos nocturnos

```
p1 = 0.00001
print(f"Evidencia 1 (accesos nocturnos): valor p = {p1}")
```

Evidencia 2: Manipulación de datos

Los datos manipulados tienen una firma estadística

Z-score de 11.5 es esencialmente imposible bajo H

```
p2 = 1e-30 # Aproximadamente 0
print(f"Evidencia 2 (manipulación datos): valor p  $\approx$  {p2}")
```

Evidencia 3: Desaparición de Ramiro

Si Ramiro huyó porque tenía miedo de Hugo...

p3 = 0.15 # Débil, pero consistente

print(f"Evidencia 3 (desaparición Ramiro): valor p = {p3}")

Evidencia 4: IP del despacho de Hugo

La IP 172.16.0.1 está física en su despacho

p4 = 0.01 # Alguien más podría haber usado su computadora

print(f"Evidencia 4 (IP física en despacho): valor p = {p4}")

Combinación: el producto de los valores p

(Esto es una simplificación, el método correcto es Fisher)

```
import math
```

```
chi_cuadrado = -2 * sum(math.log(p) for p in [p1, p2, p3, p4])
```

```
print(f"\nEstadístico combinado (Fisher): {chi_cuadrado:.2f}")
```

```
print("Con 8 grados de libertad, valor p combinado < 0.00001")
```

```
print("→ La evidencia conjunta es abrumadora")
```

—Cuanto más evidencia reunimos, más se inclina la balanza —dijo Valeria—. Pero aún tenemos un problema.

—¿Cuál?

—No tenemos **prueba directa**. Tenemos correlación, tenemos probabilidades, tenemos valores p. Pero en un tribunal, nec

—¿Qué necesitamos?

—Algo que vincule directamente a Hugo con la manipulación. Un archivo. Un email. Una confesión.

—O un testigo —dijo Marco.

—O un testigo —repitió Valeria.

Enigmas

Enigma 6.1: Calcula el valor p

Lanzas una moneda 20 veces y obtienes 15 caras. ¿Es una moneda cargada?

1. H_0 : la moneda es justa ($P(\text{cara}) = 0.5$)

2. H_1 : la moneda está cargada hacia caras

3. Simula 10000 lanzamientos de 20 monedas justas

4. ¿Cuántas veces obtienes 15 o más caras?

5. ¿Cuál es el valor p?

Enigma 6.2: Error tipo I y tipo II

Un test médico para detectar una enfermedad rara (0.1% de la población) tiene 99% de precisión:

1. Si el test da positivo, ¿cuál es la probabilidad de que sea un falso positivo (Error Tipo I)?

2. Si el test da negativo pero la persona tiene la enfermedad, ¿qué tipo de error es?

3. ¿Qué es más peligroso en este contexto?

Enigma 6.3: Diseña tu propia prueba

Tienes datos de tiempos de respuesta (en segundos) de dos sitios web:

sitio_A = [2.3, 2.1, 2.5, 2.2, 2.4, 2.0, 2.6, 2.3, 2.2, 2.5]

sitio_B = [3.1, 2.9, 3.3, 2.8, 3.0, 3.2, 2.7, 3.1, 2.9, 3.0]

1. Formula H_0 y H_1

2. Calcula las medias

3. ¿Cuál sitio es más rápido? ¿La diferencia es estadísticamente significativa?

Lo que aprendiste

- La **hipótesis nula (H_0)** es lo que asumimos por defecto

```

- La hipótesis alternativa ( $H_1$ ) es lo que queremos demostrar
- El valor p es la probabilidad de observar los datos si  $H_0$  es cierta
- Si  $p < 0.05$ , rechazamos  $H_0$  (resultado estadísticamente significativo)
- Error Tipo I: falso positivo (rechazar  $H_0$  cuando es verdadera)
- Error Tipo II: falso negativo (no rechazar  $H_0$  cuando es falsa)
- La evidencia combinada es más poderosa que una sola prueba
-Necesito hablar con tu padre -dijo Valeria-. Cara a cara.
-¿Y qué le vas a decir?
-Le voy a mostrar los números. Y voy a ver su reacción.
-¿Y si es culpable?
Valeria guardó su laptop.
-Entonces los números serán lo único que nos salve.
# Capítulo 7: La Correlación del Secreto
## Conceptos: Correlación, coeficiente de Pearson, causalidad vs correlación, matriz de correlación
---
El Dr. Hugo Tupac los recibió en su despacho con una expresión que Valeria no supo interpretar. ¿Era preocupación? ¿Enoj
-Me dijeron que estaban investigando por su cuenta -dijo el director-. ¿Qué han encontrado?
Valeria colocó su laptop sobre la mesa y mostró los logs de acceso.
-Esto -dijo-. Accesos nocturnos desde la IP de su despacho al servidor del ministerio. La misma noche en que Kamila muri
El Dr. Tupac observó la pantalla en silencio.
-No fui yo -dijo finalmente-. Esa noche estaba en una cena con el ministro. Tengo testigos.
-¿Alguien más tiene acceso a su computadora?
-Solo yo. Pero... la puerta de mi despacho no tiene llave física. Es biométrica. Cualquiera con acceso al octavo piso pu
-¿Quién tiene acceso al octavo piso?
-Mi asistente. El personal de limpieza. Y... Kamila.
-¿Kamila?
-Sí. Ella venía a verme a menudo. Y a veces, cuando yo no estaba, dejaba documentos en mi escritorio.
Valeria procesó la información. ¿Era posible que Kamila misma hubiera accedido al servidor desde el despacho de Hugo? ¿O
-Necesito ver algo -dijo Valeria-. Las bitácoras de entrada al octavo piso.
-Puedo conseguírtelas -dijo Hugo-. Pero me vas a tener que explicar qué estás buscando.
-Estoy buscando correlaciones.
---
## Correlación: la danza de los números
-La correlación mide la relación entre dos variables. Si una aumenta y la otra también, tienen correlación positiva.
-El coeficiente de correlación de Pearson ( $r$ ) va de -1 a +1:
-  $r = +1$ : correlación positiva perfecta
-  $r = 0$ : sin correlación
-  $r = -1$ : correlación negativa perfecta
Valeria abrió Python:

```

Correlación en Python

```

import numpy as np
import random
import math

```

Ejemplos de correlación

1. Correlación positiva perfecta ($r \approx 1$)

```

horas_estudio = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
notas_examen = [2.0, 3.5, 4.0, 5.5, 6.0, 7.5, 8.0, 9.5, 9.0, 10.0]
r_positivo = np.corrcoef(horas_estudio, notas_examen)[0, 1]
print(f"Correlación (horas estudio vs nota): {r_positivo:.3f}")

```

2. Correlación negativa perfecta ($r \approx -1$)

```

edad_auto = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]

```

```
precio_auto = [30000, 27000, 24000, 21000, 18000, 15000, 12000, 9000, 6000, 3000]
r_negativo = np.corrcoef(edad_auto, precio_auto)[0, 1]
print(f"Correlación (edad del auto vs precio): {r_negativo:.3f}")
```

3. Sin correlación ($r \approx 0$)

```
random.seed(42)
x_aleatorio = [random.gauss(0, 1) for _ in range(50)]
y_aleatorio = [random.gauss(0, 1) for _ in range(50)]
r_cero = np.corrcoef(x_aleatorio, y_aleatorio)[0, 1]
print(f"Correlación (datos aleatorios): {r_cero:.3f}")
```

Resultado:

```
Correlación (horas estudio vs nota): 0.976
Correlación (edad del auto vs precio): -0.997
Correlación (datos aleatorios): 0.042
```

```
---
## El problema: correlación no es causalidad
-Pero aquí está el error más común en estadística -dijo Valeria-: confundir **correlación con causalidad**.
-¿Qué significa eso?
-Que porque dos cosas estén correlacionadas, no significa que una cause la otra.
Valeria escribió:
```

Ejemplos de correlaciones falsas

Ejemplo 1: Ventas de helados y ahogados

```
meses = list(range(1, 13))
ventas_helados = [10, 12, 15, 25, 40, 55, 60, 58, 45, 30, 18, 12]
ahogados_playa = [2, 3, 4, 8, 15, 22, 25, 24, 16, 9, 5, 3]
r_helados_ahogados = np.corrcoef(ventas_helados, ahogados_playa)[0, 1]
print(f"Correlación (helados vs ahogados): {r_helados_ahogados:.3f}")
print("¿Los helados causan ahogados? ¡NO!")
print("Variable oculta: el CALOR (en verano se venden más helados y más gente va a la playa)")
print()
```

Ejemplo 2: Número de iglesias y crímenes (Datos ficticios para ilustrar)

```
ciudades = ['A', 'B', 'C', 'D', 'E']
iglesias = [5, 10, 15, 20, 25]
tasa_crimen = [20, 35, 45, 55, 70]
r_iglesias_crimen = np.corrcoef(iglesias, tasa_crimen)[0, 1]
print(f"Correlación (iglesias vs crímenes): {r_iglesias_crimen:.3f}")
print("¿Las iglesias causan crímenes? ¡NO!")
print("Variable oculta: POBLACIÓN (ciudades más grandes tienen más iglesias y más crímenes)")
```

Resultado:

Correlación (helados vs ahogados): 0.987

¿Los helados causan ahogados? ¡NO!

Variable oculta: el CALOR (en verano se venden más helados y más gente va a la playa)

Correlación (iglesias vs crímenes): 0.993

¿Las iglesias causan crímenes? ¡NO!

Variable oculta: POBLACIÓN (ciudades más grandes tienen más iglesias y más crímenes)

```
-En nuestro caso -dijo Valeria-, tenemos una correlación entre la IP de Hugo y los accesos nocturnos. Pero eso no signif
-¿Como qué?
-Como que alguien más usó su computadora. O que Kamila misma accedió desde allí para investigar. O que el sistema de log
---
## Matriz de correlación del caso
Valeria cargó los datos completos.
```

Matriz de correlación de las variables del caso

```
import pandas as pd
```

Datos simulados del caso

```
datos_caso = pd.DataFrame({
'sospechoso': ['Ramiro', 'Hugo', 'Sofia', 'Proveedor', 'Consultor'],
'acceso_fisico': [1, 1, 1, 0, 1],      # 1 = tiene acceso
'acceso_datos': [0.7, 0.9, 0.8, 0.1, 1], # 0-1 nivel de acceso
'motivo': [0.5, 0.3, 0.2, 0.8, 0.6],   # 0-1 nivel de motivo
'coartada': [0.1, 0.7, 0.5, 0.3, 0.4], # 0-1 solidez de coartada
'desaparicion': [1, 0, 0, 0, 0],       # 1 = desapareció
'ip_nocturna': [0, 1, 0.2, 0, 0.3],    # 0-1 frecuencia en logs nocturnos
'manipulacion': [0.3, 0.7, 0.8, 0.2, 0.6] # 0-1 evidencia de manipulación
})
```

Calculamos la matriz de correlación

```
matriz_correlacion = datos_caso.select_dtypes(include=[np.number]).corr()
print("=== MATRIZ DE CORRELACIÓN ===")
print(matriz_correlacion.round(3))
print()
```

Extraemos las correlaciones con 'manipulacion'

```
print("=== CORRELACIONES CON 'MANIPULACION' ===")
correlaciones_con_manipulacion = matriz_correlacion['manipulacion'].sort_values(ascending=False)
print(correlaciones_con_manipulacion.round(3))
```

Resultado:

```
=== MATRIZ DE CORRELACIÓN ===
acceso_fisico  acceso_datos  motivo  coartada  desaparicion  ip_nocturna  manipulacion
acceso_fisico      1.000      0.707  -0.707   -0.000     -0.707      0.000      0.000
```

acceso_datos	0.707	1.000	-0.677	0.632	-0.535	0.574	0.707
motivo	-0.707	-0.677	1.000	-0.535	0.189	-0.542	-0.394
coartada	-0.000	0.632	-0.535	1.000	-0.632	0.316	0.316
desaparicion	-0.707	-0.535	0.189	-0.632	1.000	-0.189	-0.189
ip_nocturna	0.000	0.574	-0.542	0.316	-0.189	1.000	0.872
manipulacion	0.000	0.707	-0.394	0.316	-0.189	0.872	1.000

=== CORRELACIONES CON 'MANIPULACION' ===

```
manipulacion    1.000
ip_nocturna     0.872
acceso_datos    0.707
coartada        0.316
motivo          -0.394
desaparicion    -0.189
acceso_fisico   0.000
```

—Mira esto —dijo Valeria—. La variable con mayor correlación con `manipulacion` es `ip\_nocturna` (0.872). Eso significa
 —Pero —interrumpió Marco— también dijiste que correlación no es causalidad.
 —Correcto. Y por eso necesitamos la siguiente pieza del rompecabezas.

 ## El diagrama de dispersión
 Valeria creó un gráfico:

Diagrama de dispersión: acceso a datos vs manipulación

```
import matplotlib.pyplot as plt
datos_grafico = {
'Ramiro': (0.7, 0.3),
'Hugo': (0.9, 0.7),
'Sofia': (0.8, 0.8),
'Proveedor': (0.1, 0.2),
'Consultor': (1.0, 0.6)
}
nombres = list(datos_grafico.keys())
accesos = [datos_grafico[n][0] for n in nombres]
manipulaciones = [datos_grafico[n][1] for n in nombres]
plt.figure(figsize=(8, 6))
plt.scatter(accesos, manipulaciones, s=100)
for i, nombre in enumerate(nombres):
plt.annotate(nombre, (accesos[i], manipulaciones[i]),
xytext=(5, 5), textcoords='offset points')
plt.xlabel('Nivel de Acceso a Datos')
plt.ylabel('Evidencia de Manipulación')
plt.title('Acceso a Datos vs Manipulación')
```



```
plt.grid(True, alpha=0.3)
```

Línea de tendencia

```
z = np.polyfit(accesos, manipulaciones, 1)
```

```
p = np.poly1d(z)
```

```
x_line = np.linspace(0, 1, 100)
```

```
plt.plot(x_line, p(x_line), 'r--', alpha=0.7)
```

```
plt.show()
```

```
—Sofía y Hugo están en la zona de alta correlación —dijo Valeria—. Pero Sofía tiene más evidencia de manipulación (0.8)
—¿Entonces podría ser Sofía? —preguntó Marco.
—O podría ser que Hugo y Sofía estén trabajando juntos. O que uno esté incriminando al otro.
---
```

```
## Enigmas
```

```
### Enigma 7.1: Calcula la correlación
```

```
Dados los siguientes datos de publicidad vs ventas:
```

```
publicidad = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
```

```
ventas = [12, 15, 18, 20, 22, 25, 28, 30, 32, 35]
```

```
1. Calcula el coeficiente de correlación de Pearson
```

```
2. Interpreta el resultado
```

```
### Enigma 7.2: Correlación falsa
```

```
Propón tres ejemplos de correlaciones falsas (donde dos variables están correlacionadas pero no hay relación causal). Pa
```

```
### Enigma 7.3: Matriz del caso
```

```
Agrega un nuevo sospechoso a la matriz: la asistente de Kamila, llamada "Lidia", con estos valores:
```

```
- acceso_fisico: 0
- acceso_datos: 0.6
- motivo: 0.4
- coartada: 0.8
- desaparicion: 0
- ip_nocturna: 0.5
- manipulacion: 0.4
```

```
Recalcula la matriz de correlación. ¿Cambia la interpretación?
```

```
---
```

```
## Lo que aprendiste
```

```
- La **correlación** mide la relación entre dos variables (-1 a +1)
- **Pearson (r)**: mide correlación lineal
- **r ≈ 0**: sin correlación
- **Correlación no implica causalidad**: puede haber variables ocultas
- La **matriz de correlación** muestra relaciones entre múltiples variables
- Los **diagramas de dispersión** visualizan correlaciones
```

```
—Sofía —dijo Valeria—. Necesito hablar con Sofía.
```

```
—No vas a poder —dijo Hugo—. Tomó una semana de vacaciones. Justo después de la muerte de Kamila.
```

```
Valeria sintió que las piezas comenzaban a encajar.
```

```
—¿Dónde se fue?
```

```
—No lo dijo. Pero tengo su dirección de emergencia. Un pueblo en el Valle Sagrado.
```

```
—Entonces —dijo Valeria levantándose—, creo que es hora de hacer un viaje.
```

```
# Capítulo 8: La Regresión del Pasado
```

```
## Conceptos: Regresión lineal, recta de mejor ajuste, R2, predicción
```

```
---
```

```
El viaje al Valle Sagrado tomó tres horas. Valeria y Marco alquilaron un auto y recorrieron la carretera que serpenteaba
```

```
—¿Qué sabes de Sofía? —preguntó Valeria.
```

```
—Poco —dijo Marco—. Trabajaba con Kamila desde hacía dos años. Era su asistente de investigación. Muy callada, muy efici
```

```
—Eso es sospechoso en sí mismo.
```

```
—¿Por qué?
```

```
—Porque en estadística, los valores atípicos son los más interesantes. Pero también lo son los valores que se esconden e
Llegaron a un pequeño pueblo llamado Pachar. La dirección de Sofía era una casa de adobe al final de una calle empedrada
Una mujer mayor abrió.
```

```
—¿Sofía? —preguntó Valeria.
```

```
—No está —respondió la mujer—. Se fue ayer. Dijo que tenía que regresar a la ciudad.
```

```
—¿Dijo algo más?
```

```
La mujer dudó. Luego sacó un sobre de su delantal.
```

```

-Dijo que si alguien venía preguntando por ella, les diera esto.
Valeria abrió el sobre. Dentro había una memoria USB y una nota que decía:
*"Lo siento. No sabía en lo que me estaba metiendo. Esto es lo que sé. – Sofía"*
---
## Los datos de Sofía
Valeria conectó la memoria USB a su laptop. Contenía un único archivo: `regresion_secreta.csv`.
-Son datos de ventas de un medicamento -dijo Valeria-. Pero no cualquier medicamento. Es el mismo del ensayo clínico man
-¿Qué muestra?
-Vamos a verlo con regresión lineal.
---
## Regresión lineal: encontrando la línea oculta
-La regresión lineal nos permite encontrar la relación entre una variable dependiente (Y) y una o más variables inde
-La fórmula de una línea recta es:

$$Y = mX + b$$

Donde:
- m es la pendiente (cuánto cambia Y por cada unidad de X)
- b es el intercepto (el valor de Y cuando X = 0)
Valeria abrió Python:

```

Regresión lineal con Python

```

import numpy as np
import csv
import math

```

Cargamos los datos de Sofía

```

datos_ventas = []
with open('regresion_secreta.csv', 'r') as f:
    lector = csv.DictReader(f)
    for fila in lector:
        datos_ventas.append({
            'mes': int(fila['mes']),
            'gasto_publicidad': float(fila['gasto_publicidad']),
            'ventas': float(fila['ventas']),
            'pacientes': int(fila['pacientes'])
        })
    print(f"Registros cargados: {len(datos_ventas)}")
    print(f"Rango de meses: {datos_ventas[0]['mes']} - {datos_ventas[-1]['mes']}")
    print()

```

Extraemos variables

```

X = np.array([d['gasto_publicidad'] for d in datos_ventas]) # Gasto en publicidad
Y = np.array([d['ventas'] for d in datos_ventas])          # Ventas

```

Calculamos la regresión lineal manualmente

```

n = len(X)
media_x = np.mean(X)
media_y = np.mean(Y)

```

Pendiente (m)

```
numerador = sum((X[i] - media_x) (Y[i] - media_y) for i in range(n))
```

```
denominador = sum((X[i] - media_x) 2 for i in range(n))
```

```
pendiente = numerador / denominador
```

Intercepto (b)

```
intercepto = media_y - pendiente media_x
```

```
print(f"=== REGRESIÓN LINEAL ===")
```

```
print(f"Ecuación: Ventas = {pendiente:.2f} × Publicidad + ({intercepto:.2f})")
```

```
print(f"Interpretación: por cada $1,000 en publicidad, las ventas aumentan en ${pendiente1000:.0f}")
```

Resultado:

Registros cargados: 24

Rango de meses: 1 - 24

=== REGRESIÓN LINEAL ===

Ecuación: Ventas = 3.45 × Publicidad + (12.30)

Interpretación: por cada \$1,000 en publicidad, las ventas aumentan en \$3,450

—Pero hay algo raro —dijo Valeria—. La relación debería ser consistente. Veamos los residuos.

Los residuos: lo que la línea no explica

—Los **residuos** son las diferencias entre los valores reales y los valores predichos por la línea de regresión. Si los

Calculamos predicciones y residuos

```
predicciones = pendiente X + intercepto
```

```
residuos = Y - predicciones
```

```
print(f"\n=== ANÁLISIS DE RESIDUOS ===")
```

```
print(f"{'Mes':<6} {'Real':<10} {'Predicho':<12} {'Residuo':<10}")
```

```
print("-" 38)
```

```
for i in range(n):
```

```
print(f"{datos_ventas[i]['mes']:<6} {Y[i]:<10.1f} {predicciones[i]:<12.1f} {residuos[i]:<10.1f}")
```

Varianza de los residuos

```
var_residuos = np.var(residuos)
```

```
var_total = np.var(Y)
```

```
r_cuadrado = 1 - (var_residuos / var_total)
```

```
print(f"\nVarianza de residuos: {var_residuos:.2f}")
```

```
print(f"Varianza total: {var_total:.2f}")
```

```
print(f"R² (coeficiente de determinación): {r_cuadrado:.3f}")
```

```
print(f"Interpretación: el {r_cuadrado100:.1f}% de la variación en ventas")
```

```
print(f" es explicada por el gasto en publicidad")
```

Resultado:

=== ANÁLISIS DE RESIDUOS ===

Mes	Real	Predicho	Residuo
1	50.0	48.9	1.1
2	52.0	52.4	-0.4
3	48.0	49.7	-1.7
4	55.0	53.2	1.8
5	51.0	50.1	0.9

...

23	78.0	68.0	10.0
24	82.0	69.3	12.7

Varianza de residuos: 5.82

Varianza total: 24.50

R^2 (coeficiente de determinación): 0.763

Interpretación: el 76.3% de la variación en ventas es explicada por el gasto en publicidad

```
-El  $R^2$  de 0.763 es decente -dijo Valeria-. Pero mira los últimos meses: los residuos crecen. Mes 23: residuo de 10. Mes
-¿Qué significa?
-Que en los últimos meses, las ventas son mucho más altas de lo que la publicidad predeciría. Como si alguien estuviera
---
## Detectando la manipulación con regresión
Valeria dividió los datos en dos períodos: antes y después del mes 18.
```

Dividimos los datos

```
X_antes = X[:18]
Y_antes = Y[:18]
X_despues = X[18:]
Y_despues = Y[18:]
```

Regresión para el período anterior

```
n_antes = len(X_antes)
media_x_antes = np.mean(X_antes)
media_y_antes = np.mean(Y_antes)
pendiente_antes = sum((X_antes[i] - media_x_antes) * (Y_antes[i] - media_y_antes)
for i in range(n_antes)) / sum((X_antes[i] - media_x_antes) ** 2
for i in range(n_antes))
intercepto_antes = media_y_antes - pendiente_antes * media_x_antes
```

Regresión para el período posterior

```
n_despues = len(X_despues)
media_x_despues = np.mean(X_despues)
media_y_despues = np.mean(Y_despues)
pendiente_despues = sum((X_despues[i] - media_x_despues) * (Y_despues[i] - media_y_despues)
for i in range(n_despues)) / sum((X_despues[i] - media_x_despues) ** 2
for i in range(n_despues))
```

```

for i in range(n_despues))
intercepto_despues = media_y_despues - pendiente_despues media_x_despues
print("=== COMPARACIÓN DE PERÍODOS ===")
print(f"Período 1 (meses 1-18):")
print(f" Ventas = {pendiente_antes:.2f} × Publicidad + ({intercepto_antes:.2f})")
print(f" Pendiente: {pendiente_antes:.2f}")
print()
print(f"Período 2 (meses 19-24):")
print(f" Ventas = {pendiente_despues:.2f} × Publicidad + ({intercepto_despues:.2f})")
print(f" Pendiente: {pendiente_despues:.2f}")
print()

```

Proyección: ¿qué ventas esperaríamos en los meses 19-24

si el comportamiento hubiera sido el mismo que en los meses 1-18?

```

print("=== DETECCIÓN DE ANOMALÍAS ===")
print(f"{'Mes':<6} {'Real':<10} {'Esperado':<12} {'Diferencia':<12}")
print("-" 40)
for i in range(n_despues):
real = Y_despues[i]
esperado = pendiente_antes X_despues[i] + intercepto_antes
diff = real - esperado
print(f"{'datos_ventas[18+i]':'mes':<6} {real:<10.1f} {esperado:<12.1f} {diff:<12.1f}")

```

Resultado:

=== COMPARACIÓN DE PERÍODOS ===

Período 1 (meses 1-18):

Ventas = 2.80 × Publicidad + (14.20)

Pendiente: 2.80

Período 2 (meses 19-24):

Ventas = 4.90 × Publicidad + (8.50)

Pendiente: 4.90

=== DETECCIÓN DE ANOMALÍAS ===

Mes	Real	Esperado	Diferencia
-----	------	----------	------------

19	65.0	57.3	7.7
----	------	------	-----

20	68.0	59.5	8.5
----	------	------	-----

21	72.0	60.2	11.8
----	------	------	------

22	75.0	62.8	12.2
----	------	------	------

23	78.0	65.1	12.9
24	82.0	67.4	14.6

```
-La pendiente cambió de 2.80 a 4.90 -dijo Valeria-. Eso significa que, en los últimos 6 meses, cada dólar de publicidad
-¿Y quién estuvo a cargo de los datos en esos meses?
-Según la nota de Sofia... ella misma.
---
## El R² y la calidad del modelo
-El R² (coeficiente de determinación) mide qué tan bien la línea de regresión se ajusta a los datos. Va de 0 a 1:
- R² = 1: el modelo predice perfectamente
- R² = 0: el modelo no predice nada
```

R² para ambos períodos

```
def calcular_r2(X, Y, pendiente, intercepto):
    predicciones = pendiente * X + intercepto
    residuos = Y - predicciones
    var_residuos = np.var(residuos)
    var_total = np.var(Y)
    return 1 - (var_residuos / var_total)

r2_antes = calcular_r2(X_antes, Y_antes, pendiente_antes, intercepto_antes)
r2_despues = calcular_r2(X_despues, Y_despues, pendiente_despues, intercepto_despues)
print(f"R² período 1: {r2_antes:.3f}")
print(f"R² período 2: {r2_despues:.3f}")
print()
print("Interpretación:")
if r2_despues > r2_antes:
    print("El R² aumentó: los datos del período 2 son 'demasiado perfectos'")
    print("→ Posible manipulación: los datos fueron ajustados para verse mejor")
else:
    print("El R² se mantuvo estable: los datos parecen consistentes")
```

Resultado:

R² período 1: 0.721

R² período 2: 0.958

Interpretación:

El R² aumentó: los datos del período 2 son 'demasiado perfectos'

→ Posible manipulación: los datos fueron ajustados para verse mejor

```
-Un R² de 0.958 en el segundo período significa que los datos se ajustan casi perfectamente a la línea -dijo Valeria-. E
-¿Sofía?
-O alguien usando sus credenciales.
---
## Enigmas
### Enigma 8.1: Calcula la regresión manual
Con estos datos de horas de estudio y notas:
```

horas = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]

notas = [3.0, 4.0, 5.0, 5.5, 6.5, 7.0, 8.0, 8.5, 9.0, 9.5]

```
1. Calcula la pendiente y el intercepto
2. ¿Qué nota predecirías para 7.5 horas de estudio?
3. Calcula el R²
```

```
### Enigma 8.2: Detecta la manipulación
¿Cuál de estos conjuntos de datos parece manipulado? ¿Por qué?
```

Conjunto A

Xa = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]

Ya = [15, 18, 20, 22, 25, 28, 30, 33, 35, 38]

Conjunto B

Xb = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]

Yb = [12, 25, 18, 30, 22, 35, 28, 40, 32, 45]

```
### Enigma 8.3: Predice el futuro
Usando la regresión del período 1 (Ventas = 2.80 × Publicidad + 14.20), predice las ventas para los meses 25 y 26 si el
---
## Lo que aprendiste
- La **regresión lineal** encuentra la línea de mejor ajuste ( $Y = mX + b$ )
- La **pendiente (m)** mide el cambio en Y por unidad de cambio en X
- El **intercepto (b)** es el valor de Y cuando  $X = 0$ 
- Los **residuos** son las diferencias entre valores reales y predichos
- El R2 mide qué tan bien se ajusta el modelo (0 a 1)
- Residuos crecientes en el tiempo → posible manipulación
-Sofía nos dejó la evidencia, pero huyó –dijo Marco–. Eso la hace sospechosa.
-O la hace la próxima víctima –respondió Valeria–. Tenemos que encontrarla antes de que alguien más lo haga.
-¿Y cómo la encontramos?
Valeria miró los datos de la regresión.
-Usando el modelo. Si sabemos cómo se mueve, podemos predecir dónde estará.
# Capítulo 9: El Intervalo de Confianza
## Conceptos: Intervalo de confianza, nivel de confianza, margen de error, distribución muestral
---
Sofía no estaba en Pachar. La mujer de la casa dijo que había tomado un bus hacia Ollantaytambo temprano esa mañana. Val
-¿Cómo sabemos que vamos en la dirección correcta? –preguntó Marco.
-No lo sabemos –admitió Valeria–. Pero podemos estimarlo.
-¿Estimarlo?
-Con un **intervalo de confianza**.
---
## El intervalo de confianza
-Un **intervalo de confianza** es un rango de valores dentro del cual esperamos que se encuentre el valor real de un par
-Por ejemplo, si decimos "el 95% de los peruanos tiene entre 25 y 35 años", ese es un intervalo de confianza del 95%.
-Pero no significa que haya un 95% de probabilidad de que la media esté en ese intervalo. Significa que, si repitiéramos
Valeria abrió Python:
```

Intervalo de confianza

```
import numpy as np
import random
import math
```

EJEMPLO: Estimando la edad promedio de los estudiantes del ICD

Tomamos una muestra de 50 estudiantes

```
random.seed(42)
muestra_edades = [random.gauss(25, 5) for _ in range(50)]
edad_media_muestral = np.mean(muestra_edades)
```

```

desv_std_muestral = np.std(muestra_edades, ddof=1) # ddof=1 para muestra
n = len(muestra_edades)
print("=== INTERVALO DE CONFIANZA ===")
print(f"Tamaño de muestra: {n}")
print(f"Media muestral: {edad_media_muestral:.2f} años")
print(f"Desviación estándar muestral: {desv_std_muestral:.2f} años")
print()

```

Para un intervalo de confianza del 95%:

IC = media ± (valor_crítico × error_estándar)

error_estándar = desv_std / sqrt(n)

valor_crítico para 95% ≈ 1.96 (distribución normal)

```

nivel_confianza = 0.95
valor_critico = 1.96
error_estandar = desv_std_muestral / math.sqrt(n)
margen_error = valor_critico * error_estandar
ic_inferior = edad_media_muestral - margen_error
ic_superior = edad_media_muestral + margen_error
print(f"Intervalo de confianza del {nivel_confianza*100:.0f}%:")
print(f" [{ic_inferior:.2f}, {ic_superior:.2f}]")
print(f" Margen de error: ±{margen_error:.2f}")
print()
print("Interpretación: tenemos un 95% de confianza")
print("de que la media real de la población está entre")
print(f"{ic_inferior:.2f} y {ic_superior:.2f} años.")

```

Resultado:

```

=== INTERVALO DE CONFIANZA ===
Tamaño de muestra: 50
Media muestral: 24.87 años
Desviación estándar muestral: 4.83 años
Intervalo de confianza del 95%:
[23.53, 26.21]
Margen de error: ±1.34
Interpretación: tenemos un 95% de confianza
de que la media real de la población está entre
23.53 y 26.21 años.

```

```

-Ahora -dijo Valeria-, apliquemos esto a nuestra búsqueda de Sofía.
---
## Buscando a Sofía con intervalos

```


Valeria abrió los registros de su teléfono.

–Sofía usó su tarjeta de crédito tres veces después de desaparecer: una en una gasolinera en Chinchero, otra en un resta

–Está yendo hacia Machu Picchu –dijo Marco.

–O está yendo a la frontera. Pero podemos calcular un intervalo de confianza para su ubicación actual.

Estimando la ubicación de Sofía

Distancias desde Pachar (km)

pachar = 0

chinchero = 15

urubamba = 35

ollantaytambo = 60

aguas_calientes = 85 # Machu Picchu

frontera = 200 # Frontera con Bolivia

Tiempos desde su desaparición (horas)

horas_desde_desaparicion = 18

Velocidad promedio de viaje (km/h)

Estimación: entre 30 y 60 km/h (transporte público en la región)

velocidad_min = 30

velocidad_max = 60

Distancia mínima y máxima recorrida

distancia_min = velocidad_min * horas_desde_desaparicion

distancia_max = velocidad_max * horas_desde_desaparicion

print("=== ESTIMACIÓN DE UBICACIÓN ===")

print(f"Horas desde desaparición: {horas_desde_desaparicion}")

print(f"Velocidad estimada: {velocidad_min}–{velocidad_max} km/h")

print(f"Distancia recorrida: {distancia_min}–{distancia_max} km")

print()

Radio de búsqueda desde el último punto conocido (Ollantaytambo)

ultima_ubicacion = ollantaytambo

radio_busqueda_min = distancia_min - (ollantaytambo - pachar)

radio_busqueda_max = distancia_max - (ollantaytambo - pachar)

print(f"Última ubicación conocida: Ollantaytambo (km {ultima_ubicacion})")

print(f"Radio de búsqueda: {radio_busqueda_min:.0f}–{radio_busqueda_max:.0f} km desde Ollantaytambo")

```
print()
```

Probabilidad estimada por destino

```
destinos = {
'Aguas Calientes (MP)': 85,
'Cusco': 60,
'Frontera Bolivia': 200,
'Selva (Malvinas)': 150
}

print("Probabilidad estimada por destino (basada en distancia):")
for destino, distancia in destinos.items():
if distancia_min <= distancia <= distancia_max:
print(f" {destino}: DENTRO del intervalo de confianza")
elif distancia < distancia_min:
print(f" {destino}: demasiado cerca (ya debería haber llegado)")
else:
print(f" {destino}: demasiado lejos (no le alcanza el tiempo)")
```

Resultado:

=== ESTIMACIÓN DE UBICACIÓN ===

Horas desde desaparición: 18

Velocidad estimada: 30-60 km/h

Distancia recorrida: 540-1080 km

Última ubicación conocida: Ollantaytambo (km 60)

Radio de búsqueda: 480-1020 km desde Ollantaytambo

-Con ese radio, podría estar en casi cualquier parte del sur del Perú —dijo Marco.

-Por eso necesitamos más datos. Los intervalos de confianza se estrechan cuando tenemos más información.

Estrechando el intervalo

Valeria revisó los registros telefónicos de Sofía.

-Su teléfono hizo una llamada a las 6 a.m. de hoy. Duró 30 segundos. La torre que la registró está en la carretera hacia

Nueva información: llamada registrada en Abancay

Abancay está a 150 km de Ollantaytambo

torre_abancay = 150 # km desde Pachar

hora_llamada = 6 # a.m.

hora_actual = 11 # a.m.

Con esta información, ajustamos el intervalo

Sabemos que hace 5 horas estaba en Abancay (km 150)

distancia_desde_abancay_min = velocidad_min (hora_actual - hora_llamada)

distancia_desde_abancay_max = velocidad_max (hora_actual - hora_llamada)

```
print("=== INTERVALO ACTUALIZADO ===")
print(f"Última ubicación confirmada: Abancay (km 150) a las 6 a.m.")
print(f"Tiempo desde entonces: {hora_actual - hora_llamada} horas")
print(f"Distancia desde Abancay: {distancia_desde_abancay_min:.0f}-{distancia_desde_abancay_max:.0f} km")
print()
```

Nuevos destinos probables

```
destinos_actualizados = {
    'Abancay': 150,
    'Andahuaylas': 220,
    'Ayacucho': 350,
    'Nazca': 500,
    'Arequipa': 550,
    'Cusco (retorno)': 60
}
print("Destinos probables (actualizado):")
for destino, distancia in sorted(destinos_actualizados.items(), key=lambda x: x[1]):
    if distancia_desde_abancay_min <= distancia <= distancia_desde_abancay_max:
        prob = "ALTA"
    elif abs(distancia - distancia_desde_abancay_min) < 50 or abs(distancia - distancia_desde_abancay_max) < 50:
        prob = "MEDIA"
    else:
        prob = "BAJA"
    print(f" {destino} ({distancia} km): {prob}")
```

Resultado:

```
=== INTERVALO ACTUALIZADO ===
Última ubicación confirmada: Abancay (km 150) a las 6 a.m.
Tiempo desde entonces: 5 horas
Distancia desde Abancay: 150-300 km
Destinos probables (actualizado):
Abancay (150 km): ALTA
Andahuaylas (220 km): ALTA
Ayacucho (350 km): MEDIA
Cusco (retorno) (60 km): BAJA
Nazca (500 km): BAJA
Arequipa (550 km): BAJA
}
—Andahuaylas o Ayacucho —dijo Valeria—. Está yendo hacia la sierra sur.
—¿Y por qué iría allí?
```

—Tal vez porque allí hay alguien que puede ayudarla. O tal vez porque allí puede desaparecer para siempre.

El error estándar y la precisión

—La precisión de nuestras estimaciones depende del error estándar:

$$EE = \frac{\sigma}{\sqrt{n}}$$

—Cuanto mayor sea la muestra (n), menor será el error estándar y más preciso será nuestro intervalo.

```
# Cómo el tamaño de la muestra afecta el intervalo de confianza
print("=== EFECTO DEL TAMAÑO DE MUESTRA ===")
print(f"{'n':<10} {'Error Estándar':<18} {'Margen Error (95%)':<20} {'IC'}")
print("-" * 70)
desv_std_ejemplo = 5 # Desviación estándar típica
for n in [10, 30, 50, 100, 500, 1000]:
    error_estandar = desv_std_ejemplo / math.sqrt(n)
    margen = 1.96 * error_estandar
    print(f"{'n':<10} {'error_estandar':<18.3f} ±{'margen':<18.2f} [{25-margen:.1f}, {25+margen:.1f}]"
```

Resultado:

n	Error Estándar	Margen Error (95%)	IC
10	1.581	±3.10	[21.9, 28.1]
30	0.913	±1.79	[23.2, 26.8]
50	0.707	±1.39	[23.6, 26.4]
100	0.500	±0.98	[24.0, 26.0]
500	0.224	±0.44	[24.6, 25.4]
1000	0.158	±0.31	[24.7, 25.3]

—Cuantos más datos tenemos, más preciso es nuestro intervalo. Pero la precisión aumenta con la raíz cuadrada de n. Para duplicar la precisión, necesitamos cuadruplicar la muestra.

—Como en la investigación —dijo Marco—. Cada nueva pista nos da más precisión, pero nunca certeza absoluta.

—Exactamente. Y ahora, nuestra mejor estimación dice que Sofía va hacia Andahuaylas. Vamos.

Enigmas

Enigma 9.1: Calcula el intervalo

Una muestra de 100 personas tiene una media de ingresos de S/2,500 con una desviación estándar de S/800.

1. Calcula el error estándar
2. Calcula el intervalo de confianza del 95%
3. Interpreta el resultado

Enigma 9.2: El tamaño importa

¿Qué tamaño de muestra necesitarías para tener un margen de error de ±S/100 con 95% de confianza, si la desviación estándar es S/800?

Enigma 9.3: Aplica al caso

Si Sofía fue vista en Andahuaylas a las 8 a.m. (a 220 km de Pachar) y ahora son las 2 p.m., ¿cuál es tu intervalo de confianza para su ubicación actual? Usa velocidades de 30-60 km/h.

Lo que aprendiste

- El intervalo de confianza da un rango para el valor real de un parámetro

- El nivel de confianza (95%) indica qué tan seguros estamos
- El margen de error depende del error estándar y del nivel de confianza
- El error estándar = $\sigma / \sqrt{n}$
- Mayor muestra → menor error → intervalo más preciso
- Nunca hay certeza absoluta, solo intervalos de confianza

Valeria aceleró en la carretera hacia Andahuaylas. El intervalo de confianza decía que Sofía estaba allí. Pero los intervalos de confianza no siempre aciertan.

Y ella lo sabía.

Capítulo 10: La Varianza del Silencio

Conceptos: Varianza, desviación estándar, medidas de dispersión, coeficiente de variación

Andahuaylas era un pueblo tranquilo en lo alto de los Andes. Llegaron al mediodía, cuando el sol calentaba las calles empedradas y los mercados estaban llenos de gente.

—¿Por dónde empezamos? —preguntó Marco.

—Por el único hotel que acepta tarjetas de crédito en este pueblo —dijo Valeria—. Sofía usó su tarjeta esta mañana.

El hotel "Los Andes" estaba en la plaza principal. Valeria mostró una foto de Sofía en la recepción.

—Sí, se hospedó aquí —dijo el recepcionista—. Pero ya se fue. Salió hace una hora.

—¿Hacia dónde?

—No lo sé. Pero dejó esto en su habitación.

El recepcionista les dio un sobre cerrado. Valeria lo abrió. Dentro había una carta escrita a mano.

"Valeria:

Si estás leyendo esto, significa que lograste seguirme. Lo siento por haber huido. Pero tenía miedo. Kamila me pidió que la ayudara a investigar el fraude. No sabía que la iban a matar por eso.

Los datos que te dejé en la USB son reales. El fraude existe. Pero la persona responsable no es quien crees.

No es Hugo. No es Ramiro.

Es alguien más. Alguien que está más arriba.

Voy a buscarlo. Y si no regreso... termina lo que empezamos.

— Sofía"

—"Alguien más arriba" —repitió Marco—. ¿Qué significa?

—Significa que el director del ICD no es el último eslabón —dijo Valeria—. Hay alguien por encima de él. Tal vez en el ministerio.

—¿Y ahora qué hacemos?

—Primero, entender qué nos está diciendo Sofía con los datos que dejó. Porque si hay algo que Kamila me enseñó, es que los números siempre hablan. Solo hay que saber escuchar su varianza.

Varianza: midiendo la dispersión

—La varianza mide qué tan dispersos están los datos alrededor de la media. Si todos los datos son iguales, la varianza es cero. Si están muy dispersos, la varianza es alta.

—La fórmula de la varianza poblacional es:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

—Y la desviación estándar es la raíz cuadrada de la varianza: $\sigma = \sqrt{\sigma^2}$

—La desviación estándar es más fácil de interpretar porque está en las mismas unidades que los datos.

Valeria abrió Python:

```
# Varianza y desviación estándar
import numpy as np
import math

# Comparamos la dispersión de dos conjuntos de datos
conjunto_estable = [45, 46, 45, 47, 46, 45, 46, 45, 47, 46]
conjunto_variable = [30, 60, 25, 55, 35, 65, 20, 70, 40, 50]
print("=== COMPARACIÓN DE DISPERSIÓN ===")
print(f"{'Métrica':<25} {'Estable':<15} {'Variable':<15}")
print("-" * 55)
for nombre in ['Estable', 'Variable']:
    datos = conjunto_estable if nombre == 'Estable' else conjunto_variable
    media = np.mean(datos)
    varianza = np.var(datos)
    desv_std = np.std(datos)
    rango = max(datos) - min(datos)
    cv = (desv_std / media) * 100 # Coeficiente de variación
    if nombre == 'Estable':
        print(f"{'Media':<25} {media:<15.2f} {np.mean(conjunto_variable):<15.2f}")
        print(f"{'Varianza':<25} {varianza:<15.2f} {np.var(conjunto_variable):<15.2f}")
        print(f"{'Desviación Estándar':<25} {desv_std:<15.2f} {np.std(conjunto_variable):<15.2f}")
        print(f"{'Rango':<25} {rango:<15} {max(conjunto_variable) - min(conjunto_variable):<15}")
        print(f"{'Coef. Variación (%)':<25} {cv:<15.2f} {(np.std(conjunto_variable)/np.mean(conjunto_variable))*100:<15.2f}")
```

Resultado:

Métrica	Estable	Variable
Media	45.80	45.00
Varianza	0.56	262.50
Desviación Estándar	0.75	16.20
Rango	2	50
Coef. Variación (%)	1.63	36.00

—El conjunto estable tiene una desviación estándar de 0.75, el variable de 16.20. La diferencia es enorme. Pero la media es casi la misma: 45.8 vs 45.0.

—¿Por qué la media es similar si los datos son tan diferentes?

—Porque la media no cuenta toda la historia. Necesitamos la dispersión para entender realmente los datos.

La varianza de los datos del ministerio

Valeria aplicó esto a los datos del ministerio.

```
# Analizando la varianza de los ensayos clínicos
# Cargamos datos reales del ministerio (simulados)
# Comparación de la variabilidad antes y después de la manipulación
datos_antes = np.array([72.3, 68.1, 74.5, 71.2, 69.8, 73.0, 70.5, 75.1, 67.9, 72.8,
                        70.2, 74.0, 71.8, 69.5, 73.4, 68.7, 72.1, 70.9, 75.3, 71.5])
datos_despues = np.array([74.0, 75.0, 74.5, 75.5, 74.0, 75.0, 74.5, 75.0, 74.5, 75.0,
                        74.0, 75.0, 74.5, 75.0, 74.5, 75.0, 74.0, 75.0, 74.5, 75.0])
print("=== VARIANZA DE LOS ENSAYOS CLÍNICOS ===")
print(f"{'Métrica':<30} {'Antes':<15} {'Después':<15}")
print("-" * 60)
print(f"{'Media':<30} {np.mean(datos_antes):<15.2f} {np.mean(datos_despues):<15.2f}")
print(f"{'Varianza':<30} {np.var(datos_antes):<15.2f} {np.var(datos_despues):<15.2f}")
print(f"{'Desv. Estándar':<30} {np.std(datos_antes):<15.2f} {np.std(datos_despues):<15.2f}")
print(f"{'Coef. Variación (%)':<30} {np.std(datos_antes)/np.mean(datos_antes)*100:<15.2f} {np.std(datos_despues)/np.mean(datos_despues)*100:<15.2f}")
```

```
# Prueba de varianza (F-test simplificado)
f_estadistico = np.var(datos_antes) / np.var(datos_despues)
print(f"\nF-estadístico (varianza antes / varianza después): {f_estadistico:.2f}")
print("Si F >> 1, las varianzas son significativamente diferentes")
```

Resultado:

```
=== VARIANZA DE LOS ENSAYOS CLÍNICOS ===
Métrica                Antes          Después
-----
Media                  71.23         74.53
Varianza               4.46          0.18
Desv. Estándar         2.11          0.42
Coef. Variación (%)    2.96          0.57
F-estadístico (varianza antes / varianza después): 24.78
Si F >> 1, las varianzas son significativamente diferentes
}
-La varianza pasó de 4.46 a 0.18 –dijo Valeria–. La desviación estándar se redujo de 2.11 a 0.42. Esa reducción de varia
-¿Por qué?
-Porque cuando alguien fabrica datos, tiende a hacerlos demasiado uniformes. En la naturaleza, los datos reales tienen v
---
## El coeficiente de variación: comparando dispersiones
-El **coeficiente de variación (CV)** es la desviación estándar dividida por la media, expresada como porcentaje. Permit
$$CV = \frac{\sigma}{\mu} \times 100\%$
```

Coeficiente de variación en diferentes contextos

```
print("=== COEFICIENTE DE VARIACIÓN EN CONTEXTOS ===")
print()
contextos = [
    ("Estatura de adultos (cm)", 170, 7),
    ("Peso de adultos (kg)", 70, 12),
    ("Presión arterial (mmHg)", 120, 10),
    ("Datos manipulados (ensayo)", 74.5, 0.42),
    ("Datos reales (ensayo)", 71.2, 2.11)
]
print(f'Contexto:<40> {'Media':<12> {'Desv.Std':<12> {'CV (%)':<12>})
print("-" 76)
for contexto, media, desv in contextos:
    cv = (desv / media) 100
    print(f'{contexto:<40> {'media:<12> {'desv:<12.2f> {'cv:<12.2f>})
```

Resultado:

```
=== COEFICIENTE DE VARIACIÓN EN CONTEXTOS ===
Contexto                Media      Desv.Std   CV (%)

Estatura de adultos (cm)    170        7.00      4.12
Peso de adultos (kg)       70         12.00     17.14
Presión arterial (mmHg)    120        10.00      8.33
Datos manipulados (ensayo)  74.5       0.42       0.56
Datos reales (ensayo)      71.2       2.11       2.96
```

–El CV de los datos manipulados es 0.56% –dijo Valeria–. Es decir, casi no hay variación. En cambio, los datos reales ti
–Eso significa que los datos manipulados son estadísticamente imposibles.
–Exactamente. Y esa es la **varianza del silencio**: cuando alguien quiere ocultar algo, los datos se vuelven sospechosa

```
---  
## Aplicación: detectando fraudes con varianza
```

```
—Hay un método llamado **detección de dígitos de Benford** que se usa para detectar fraudes contables —dijo Valeria—. Pe
```

Detectando fraudes con la varianza

```
def detectar_fraude(datos, umbral_cv=1.0):  
    """Detecta posible fraude basado en el coeficiente de variación"""  
    media = np.mean(datos)  
    desv_std = np.std(datos)  
    cv = (desv_std / media) * 100  
    print(f"Media: {media:.2f}")  
    print(f"Desviación estándar: {desv_std:.2f}")  
    print(f"CV: {cv:.2f}%")  
    if cv < umbral_cv:  
        print(f" ALERTA: CV ({cv:.2f}%) < umbral ({umbral_cv}%)")  
        print(" Posible manipulación detectada")  
        return True  
    else:  
        print(f" CV ({cv:.2f}%) normal")  
        return False  
    print("=== DETECCIÓN DE FRAUDE ===")  
    print()
```

Datos sospechosos del ministerio

```
print("Análisis 1: Datos del ministerio (sospechosos)")  
detectar_fraude(datos_despues, umbral_cv=1.0)  
print()
```

Datos de otro estudio

```
print("Análisis 2: Datos de un estudio legítimo")  
datos_legitimos = np.random.normal(74.5, 2.0, 100)  
detectar_fraude(datos_legitimos, umbral_cv=1.0)
```

```
Resultado:
```

```
=== DETECCIÓN DE FRAUDE ===
```

```
Análisis 1: Datos del ministerio (sospechosos)
```

```
Media: 74.53
```

```
Desviación estándar: 0.42
```

```
CV: 0.57%
```

```
ALERTA: CV (0.57%) < umbral (1.00%)
```

```
Posible manipulación detectada
```

```
Análisis 2: Datos de un estudio legítimo
```

```
Media: 74.71
```


Desviación estándar: 2.13

CV: 2.85%

CV (2.85%) normal

```
-Y esto -dijo Valeria- es lo que Kamila descubrió. Algo que alguien no quería que se supiera.
---
## Enigmas
### Enigma 10.1: Calcula la varianza
Calcula la varianza y desviación estándar de:
```

datos = [12, 15, 18, 22, 25, 30, 35, 40]

```
### Enigma 10.2: Compara CV
¿Cuál de estos conjuntos tiene mayor dispersión relativa?
```

A = [100, 102, 98, 101, 99, 100, 103]

B = [10, 15, 8, 12, 20, 5, 18]

```
Usa el coeficiente de variación para compararlos.
### Enigma 10.3: Detecta el fraude
¿Cuál de estos conjuntos de datos parece manipulado? Justifica tu respuesta con estadísticas.
```

estudio_X = [72, 71, 73, 72, 71, 73, 72, 71, 73, 72]

estudio_Y = [68, 75, 70, 74, 69, 76, 71, 73, 72, 70]

```
---
## Lo que aprendiste
- La **varianza** mide la dispersión de los datos alrededor de la media
- La **desviación estándar** es la raíz cuadrada de la varianza
- El **coeficiente de variación (CV)** =  $(\sigma/\mu) \times 100$  permite comparar dispersiones
- Datos con muy baja variabilidad (CV < 1%) pueden ser manipulados
- La variabilidad natural es una firma de autenticidad en los datos
-Tenemos la prueba estadística del fraude -dijo Valeria-. Y tenemos la carta de Sofía. Ahora necesitamos encontrar a la
-¿Y quién es?
-Alguien en el Ministerio de Salud. Alguien con suficiente poder para silenciar a Kamila. Y para hacer desaparecer a Sof
-¿Cómo lo encontramos?
-Con los datos que nos dejó Sofía. Y con un poco más de estadística.
Valeria guardó su laptop. La búsqueda continuaba.
# Capítulo 11: La Prueba del Chi-Cuadrado
## Conceptos: Prueba de chi-cuadrado ( $\chi^2$ ), tablas de contingencia, frecuencias observadas vs esperadas, independencia
---
Valeria recibió una llamada cuando salían de Andahuaylas. Era Ramiro.
-Encontré algo -dijo-. En los logs del ministerio. Hay un patrón de accesos que no habíamos visto.
-¿Qué tipo de patrón?
-Accesos desde una IP del Ministerio de Salud. Pero no desde una computadora cualquiera: desde el despacho del Viceminis
-¿Del viceministro?
-Sí. Y los accesos coinciden exactamente con las fechas en que los datos fueron manipulados. La probabilidad de que sea
---
## Chi-cuadrado: la prueba de independencia
-La **prueba de chi-cuadrado ( $\chi^2$ )** se usa para determinar si existe una asociación significativa entre dos variables ca
-La fórmula es:

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

Donde:
- **O** = frecuencia observada
- **E** = frecuencia esperada (si no hubiera relación)
Valeria abrió Python cuando llegaron a un café con WiFi:
```

Prueba de chi-cuadrado para el caso

```
import numpy as np
import math
from collections import Counter
```

TABLA DE CONTINGENCIA: Persona vs Acceso

Nocturno

Filas: personas (Hugo, Ramiro, Sofia, Viceministro, otros)

Columnas: accesos nocturnos (Sí, No)

Frecuencias observadas

Extraído de los logs del ministerio

```
tabla_observada = np.array([
[5, 73], # Hugo: 5 accesos nocturnos, 73 diurnos
[1, 45], # Ramiro: 1 nocturno, 45 diurnos
[3, 89], # Sofia: 3 nocturnos, 89 diurnos
[12, 28], # Viceministro: 12 nocturnos, 28 diurnos
[8, 736] # Otros: 8 nocturnos, 736 diurnos
])
personas = ['Hugo', 'Ramiro', 'Sofia', 'Viceministro', 'Otros']
total_observado = np.sum(tabla_observada)
print("=== TABLA DE CONTINGENCIA ===")
print(f"{'Persona':<18} {'Nocturnos':<12} {'Diurnos':<12} {'Total':<12}")
print("-" 54)
for i, persona in enumerate(personas):
nocturnos = tabla_observada[i, 0]
diurnos = tabla_observada[i, 1]
total = nocturnos + diurnos
print(f"{'persona':<18} {'nocturnos':<12} {'diurnos':<12} {'total':<12}")
print("-" 54)
totales_columna = np.sum(tabla_observada, axis=0)
print(f"{'Total':<18} {'totales_columna[0]':<12} {'totales_columna[1]':<12} {'total_observado':<12}")
```

Resultado:

=== TABLA DE CONTINGENCIA ===

Persona	Nocturnos	Diurnos	Total
Hugo	5	73	78
Ramiro	1	45	46
Sofia	3	89	92
Viceministro	12	28	40
Otros	8	736	744

Total 29 971 1000

-Ahora calculamos las frecuencias **esperadas**. Si no hubiera relación entre la persona y los accesos nocturnos, la pro

Frecuencias esperadas (bajo la hipótesis de independencia)

```
proporcion_nocturna = totales_columna[0] / total_observado
```

```
print(f"\nProporción general de accesos nocturnos: {proporcion_nocturna:.4f} ({proporcion_nocturna*100:.1f}%)")
```

Frecuencias esperadas para cada celda

$$E = (\text{total_fila} * \text{total_columna}) / \text{total_general}$$

```
tabla_esperada = np.zeros_like(tabla_observada, dtype=float)
```

```
for i in range(len(personas)):
```

```
total_fila = np.sum(tabla_observada[i, :])
```

```
for j in range(2):
```

```
tabla_esperada[i, j] = (total_fila * totales_columna[j]) / total_observado
```

```
print(f"\n=== FRECUENCIAS ESPERADAS ===")
```

```
print(f'{"Persona":<18} {"Nocturnos (esp)":<18} {"Diurnos (esp)":<18}')
```

```
print("-" * 54)
```

```
for i, persona in enumerate(personas):
```

```
print(f'{"persona":<18} {"tabla_esperada[i, 0]:<18.1f} {"tabla_esperada[i, 1]:<18.1f}')
```

Resultado:

Proporción general de accesos nocturnos: 0.0290 (2.9%)

=== FRECUENCIAS ESPERADAS ===

Persona	Nocturnos (esp)	Diurnos (esp)
---------	-----------------	---------------

Hugo	2.3	75.7
------	-----	------

Ramiro	1.3	44.7
--------	-----	------

Sofía	2.7	89.3
-------	-----	------

Viceministro	1.2	38.8
--------------	-----	------

Otros	21.6	722.4
-------	------	-------

-Y ahora calculamos el chi-cuadrado:

Cálculo del chi-cuadrado

```
chi_cuadrado = 0
```

```
for i in range(len(personas)):
```

```
for j in range(2):
```

```
o = tabla_observada[i, j]
```

```
e = tabla_esperada[i, j]
```

```
contribucion = (o - e) ** 2 / e
```

```
chi_cuadrado += contribucion
if contribucion > 1:
print(f" {personas[i]}: contribución significativa = {contribucion:.2f}")
print(f"\n=== RESULTADO CHI-CUADRADO ===")
print(f" $\chi^2$  = {chi_cuadrado:.2f}")
```

$$\text{Grados de libertad} = (\text{filas} - 1) * (\text{columnas} - 1) = (5-1)*(2-1) = 4$$

```
gl = (len(personas) - 1) (2 - 1)
print(f"Grados de libertad: {gl}")
```

Valor crítico para $\alpha = 0.05$ con 4 gl ≈ 9.49

```
valor_critico = 9.49
print(f"Valor crítico ( $\alpha=0.05$ ): {valor_critico}")
if chi_cuadrado > valor_critico:
print(f"→  $\chi^2$  ({chi_cuadrado:.2f}) > valor crítico ({valor_critico})")
print(f"→ RECHAZAMOS H: existe relación significativa entre")
print(f" la persona y los accesos nocturnos")
else:
print(f"→ No hay evidencia suficiente para rechazar H")
```

Resultado:

```
Hugo: contribución significativa = 3.37
Viceministro: contribución significativa = 103.20
Otros: contribución significativa = 8.81
=== RESULTADO CHI-CUADRADO ===
 $\chi^2$  = 117.82
Grados de libertad: 4
Valor crítico ( $\alpha=0.05$ ): 9.49
→  $\chi^2$  (117.82) > valor crítico (9.49)
→ RECHAZAMOS H: existe relación significativa entre
la persona y los accesos nocturnos
```

```
-El chi-cuadrado es 117.82 -dijo Valeria-. El valor crítico para 95% de confianza es 9.49. Esto es más de 10 veces el va
-¿Y qué significa eso exactamente?
-Que la probabilidad de que esta distribución sea producto del azar es esencialmente cero. El Viceministro tiene una can
-El Viceministro es nuestro hombre -dijo Marco.
-Estadísticamente, sí. Ahora necesitamos la prueba directa.
---
## La prueba de bondad de ajuste
-Hay otra forma de usar chi-cuadrado -dijo Valeria-: la **prueba de bondad de ajuste**. Sirve para ver si una distribuci
-Por ejemplo, si los datos del ensayo clínico siguieran una distribución normal, las frecuencias deberían distribuirse d
```

Prueba de bondad de ajuste para los datos del ensayo

Datos observados del ensayo (tratamiento A)

```
mejora_observada = 470
no_mejora_observada = 30
```

Frecuencias esperadas bajo H (sin efecto del tratamiento)

Si el tratamiento no tuviera efecto, esperaríamos la misma

proporción de mejora que en el grupo de control (48%)

```
tasa_control = 0.48
mejora_esperada = 500 * tasa_control
no_mejora_esperada = 500 * (1 - tasa_control)
print("=== PRUEBA DE BONDAD DE AJUSTE ===")
print(f"{'':<20} {'Observado':<15} {'Esperado':<15} {'(O-E)²/E':<15}")
print("-" 65)
for categoria, obs, esp in [("Mejora", mejora_observada, mejora_esperada),
                           ("No mejora", no_mejora_observada, no_mejora_esperada)]:
    contrib = (obs - esp) ** 2 / esp
    print(f"{categoria:<20} {obs:<15} {esp:<15.1f} {contrib:<15.2f}")
chi2_bondad = (mejora_observada - mejora_esperada)**2 / mejora_esperada + \
    (no_mejora_observada - no_mejora_esperada)**2 / no_mejora_esperada
print(f"\nχ² (bondad de ajuste) = {chi2_bondad:.2f}")
print(f"Grados de libertad: 1")
print(f"Valor crítico (α=0.05): 3.84")
print(f"→ {'RECHAZAMOS' if chi2_bondad > 3.84 else 'NO RECHAZAMOS'} H")
print(f"→ Los datos NO siguen la distribución esperada")
print(f"→ El tratamiento A tiene un efecto estadísticamente")
print(f"significativo... pero es DEMASIADO significativo")
```

Resultado:

=== PRUEBA DE BONDAD DE AJUSTE ===

Observado	Esperado	(O-E)²/E
-----------	----------	----------

Mejora	470	240.0	220.42
--------	-----	-------	--------

No mejora	30	260.0	203.46
-----------	----	-------	--------

χ^2 (bondad de ajuste) = 423.88

Grados de libertad: 1

Valor crítico ($\alpha=0.05$): 3.84

→ RECHAZAMOS H

→ Los datos NO siguen la distribución esperada

→ El tratamiento A tiene un efecto estadísticamente significativo... pero es DEMASIADO significativo

```
-423.88 -dijo Valeria-. Para que te des una idea, un chi-cuadrado de 10 ya es extremadamente significativo. Esto es 40 v
-No hay duda -dijo Marco-. Los datos fueron fabricados.
-Y el Viceministro es el responsable estadístico. Pero la estadística no es una condena judicial. Necesitamos la evidenc
---
## El veredicto estadístico
-En estadística -dijo Valeria-, nunca decimos "esto es cierto". Decimos "rechazamos la hipótesis nula con un nivel de co
```

Resumen de toda la evidencia estadística

```
print("=== RESUMEN DE EVIDENCIA ESTADÍSTICA ===")
print()
evidencia = [
("Manipulación de datos del ensayo", "Z-score = 11.5", "Extremadamente significativo"),
("Accesos nocturnos del Viceministro", f" $\chi^2 = \{chi\_cuadrado:.1f\}$  (gl=4)", "p < 0.00001"),
("Reducción artificial de varianza", "CV: 2.96% → 0.56%", "Firma de manipulación"),
("Correlación IP-nocturna", "r = 0.87", "Correlación muy fuerte"),
("Regresión inconsistente", "R²: 0.72 → 0.96", "Datos 'demasiado perfectos'"),
("Desaparición de Ramiro y Sofía", "Bayes: P(culpable|evidencia) = 0.85", "Probabilidad alta"),
]
print(f"{'Evidencia':<45} {'Estadístico':<35} {'Conclusión':<35}")
print("-" 115)
for item in evidencia:
print(f"{item[0]:<45} {item[1]:<35} {item[2]:<35}")
print()
print("→ La evidencia estadística apunta al Viceministro de Salud")
print("→ Pero necesitamos la prueba definitiva")
```

```
-¿Y cuál es la prueba definitiva? -preguntó Marco.
-Un confesión. O un documento que lo vincule directamente.
-¿Y cómo conseguimos eso?
Valeria guardó su laptop.
-Hablando con la única persona que puede dártelo: el propio Viceministro.
---
## Enigmas
### Enigma 11.1: Calcula chi-cuadrado
Tienes una encuesta sobre preferencia política por género:
|         | Hombre | Mujer |
|-----|-----|-----|
| Partido A | 120 | 80 |
| Partido B | 90 | 110 |
1. Calcula las frecuencias esperadas
2. Calcula el chi-cuadrado
3. ¿Hay relación entre género y preferencia política?
### Enigma 11.2: Bondad de ajuste
Un dado se lanza 120 veces con estos resultados:
| Cara | 1 | 2 | 3 | 4 | 5 | 6 |
|-----|---|---|---|---|---|---|
| Frecuencia | 25 | 18 | 22 | 20 | 15 | 20 |
¿El dado está cargado? Usa chi-cuadrado con  $\alpha = 0.05$ .
### Enigma 11.3: Aplica al caso
Si agregamos una nueva fila a la tabla de contingencia con los datos de un nuevo sospechoso llamado "Ministro" que tiene
---
## Lo que aprendiste
```

```

- La **prueba de chi-cuadrado ( $\chi^2$ )** evalúa la relación entre variables categóricas
-  $\chi^2 = \sum((O - E)^2 / E)$ 
- **Tablas de contingencia**: organizan frecuencias observadas
- **Frecuencias esperadas**: las que esperaríamos si no hubiera relación
- **Bondad de ajuste**: compara una distribución observada con una esperada
- Un  $\chi^2$  alto sugiere que los datos NO son producto del azar
-Vamos a Lima -dijo Valeria-. Vamos a hablar con el Viceministro.
-¿Y si es peligroso?
-Lo es. Pero Kamila merece justicia. Y los números no mienten.
Marco arrancó el auto.
-Entonces vamos.
# Capítulo 12: La Serie del Tiempo Perdido
## Conceptos: Series temporales, tendencia, estacionalidad, autocorrelación, predicción
---
Lima los recibió con su cielo gris característico. Valeria y Marco llegaron al ministerio a las 3 p.m. y pidieron una ci
Mientras esperaban, Valeria abrió su laptop.
-Antes de enfrentarlo, quiero analizar algo. Los datos que Sofía nos dejó incluyen una **serie temporal** de ventas del
-¿Qué es una serie temporal?
-Es una secuencia de datos ordenados en el tiempo. Y tiene propiedades únicas: **tendencia**, **estacionalidad** y **aut
---
## Componentes de una serie temporal
Valeria abrió Python:

```

Análisis de serie temporal de ventas del medicamento

```

import numpy as np
import random
import math

```

Datos de ventas mensuales del medicamento (36 meses)

Los primeros 24 son legítimos, los últimos 12 fueron manipulados

```

random.seed(42)
meses = list(range(1, 37))

```

Ventas legítimas (crecimiento orgánico + estacionalidad)

```

ventas_legitimas = []
for mes in meses[:24]:
    tendencia = 50 + mes * 0.8 # Crecimiento lineal
    estacionalidad = 5 * math.sin(mes * math.pi / 6) # Ciclo anual
    ruido = random.gauss(0, 3) # Variación aleatoria
    ventas_legitimas.append(tendencia + estacionalidad + ruido)

```

Ventas manipuladas (crecimiento artificial)

```

ventas_manipuladas = []

```

```
for mes in meses[24:]:
```

La tendencia se acelera artificialmente

```
tendencia = 50 + mes * 0.8 + (mes - 24) ** 3
estacionalidad = 5 * math.sin(mes * math.pi / 6)
ruido = random.gauss(0, 1) # Menos ruido (datos demasiado perfectos)
ventas_manipuladas.append(tendencia + estacionalidad + ruido)
ventas_totales = ventas_legitimas + ventas_manipuladas
print("=== SERIE TEMPORAL DE VENTAS ===")
print(f"{'Mes':<6} {'Ventas':<10} {'Período':<15}")
print("-" * 31)
for i in range(36):
    periodo = "Legítimo" if i < 24 else "MANIPULADO"
    print(f"{'meses'[i]:<6} {'ventas_totales'[i]:<10.1f} {'periodo':<15}")
```

Resultado:

```
=== SERIE TEMPORAL DE VENTAS ===
```

```
Mes  Ventas  Período
```

```
1    50.2    Legítimo
```

```
2    51.8    Legítimo
```

```
3    56.3    Legítimo
```

```
...
```

```
24   73.1    Legítimo
```

```
25   85.2    MANIPULADO
```

```
26   89.7    MANIPULADO
```

```
27   96.4    MANIPULADO
```

```
...
```

```
36   132.8   MANIPULADO
```

```
-¿Ves el salto? -preguntó Valeria-. En el mes 24, las ventas eran 73.1. En el mes 25, saltan a 85.2. Eso es un aumento d
---
```

```
## Descomposición de la serie
```

```
-Podemos descomponer la serie en tres componentes: **tendencia**, **estacionalidad** y **residuo**.
```

Descomposición simple de la serie temporal

1. Tendencia (media móvil de 12 meses)

```
def media_movil(datos, ventana):
    resultado = []
    for i in range(len(datos)):
        inicio = max(0, i - ventana // 2)
        fin = min(len(datos), i + ventana // 2 + 1)
        resultado.append(np.mean(datos[inicio:fin]))
    return resultado
```



```
tendencia = media_movil(ventas_totales, 12)
```

2. Estacionalidad (desviación mensual promedio)

```
desviaciones_mensuales = []
```

```
for mes_idx in range(12):
```

```
valores_mes = [ventas_totales[i] for i in range(mes_idx, 36, 12)]
```

```
desviaciones_mensuales.append(np.mean(valores_mes) - np.mean(ventas_totales))
```

Normalizamos para que sumen 0

```
media_desv = np.mean(desviaciones_mensuales)
```

```
estacionalidad = [d - media_desv for d in desviaciones_mensuales]
```

3. Residuo = dato - tendencia - estacionalidad

```
residuos = []
```

```
for i in range(36):
```

```
r = ventas_totales[i] - tendencia[i] - estacionalidad[i % 12]
```

```
residuos.append(r)
```

```
print("=== DESCOMPOSICIÓN (últimos 6 meses) ===")
```

```
print(f"{'Mes':<6} {'Ventas':<10} {'Tendencia':<12} {'Estacional':<12} {'Residuo':<10}")
```

```
print("-" 50)
```

```
for i in range(30, 36):
```

```
print(f"{'meses[i]:<6} {'ventas_totales[i]:<10.1f} {'tendencia[i]:<12.1f} "
```

```
f"{'estacionalidad[i % 12]:<12.2f} {'residuos[i]:<10.2f}")
```

Resultado:

```
=== DESCOMPOSICIÓN (últimos 6 meses) ===
```

Mes	Ventas	Tendencia	Estacional	Residuo
-----	--------	-----------	------------	---------

31	115.3	105.2	-2.3	12.4
----	-------	-------	------	------

32	120.1	108.1	-1.5	13.5
----	-------	-------	------	------

33	124.8	111.0	0.8	13.0
----	-------	-------	-----	------

34	127.5	113.9	2.1	11.5
----	-------	-------	-----	------

35	130.2	116.8	1.4	12.0
----	-------	-------	-----	------

36	132.8	119.7	-0.5	13.6
----	-------	-------	------	------

-Los residuos en los últimos meses son grandes y sistemáticamente positivos -dijo Valeria-. En una serie legítima, los r

```
media_residuo_legitimo = np.mean(residuos[:24])
```

```
media_residuo_manipulado = np.mean(residuos[24:])
```

```
print(f"Media de residuos (período legítimo): {media_residuo_legitimo:.2f}")
```

```
print(f"Media de residuos (período manipulado): {media_residuo_manipulado:.2f}")
```

```
print(f"Diferencia: {media_residuo_manipulado - media_residuo_legitimo:.2f}")
```

Resultado:

Media de residuos (período legítimo): -0.08

Media de residuos (período manipulado): 11.74

Diferencia: 11.82

```
-Once punto ocho dos. Eso es casi 12 unidades de ventas mensuales que no pueden explicarse por tendencia ni estacionalidad
---
## Autocorrelación: el tiempo habla
-La **autocorrelación** mide la correlación de una serie consigo misma en diferentes rezagos temporales. Si los datos fu
```

Autocorrelación simple

```
def autocorrelacion(datos, rezago):
    n = len(datos)
    if n <= rezago:
        return 0
    datos_originales = datos[:n-rezago]
    datos_rezagados = datos[rezago:]
    return np.corrcoef(datos_originales, datos_rezagados)[0, 1]
print("=== AUTO-CORRELACIÓN ===")
print(f"{'Rezago':<10} {'Período 1-24':<18} {'Período 25-36':<18}")
print("-" 46)
for rezago in [1, 2, 3, 6, 12]:
    ac_legitimo = autocorrelacion(ventas_legitimas, rezago)
    ac_manipulado = autocorrelacion(ventas_manipuladas, rezago)
    print(f"{'rezago':<10} {'ac_legitimo':<18.3f} {'ac_manipulado':<18.3f}")
```

Resultado:

=== AUTO-CORRELACIÓN ===

Rezago	Período 1-24	Período 25-36
--------	--------------	---------------

1	0.723	0.956
2	0.521	0.912
3	0.348	0.874
6	0.124	0.765
12	-0.089	0.543

```
-La autocorrelación es mucho más alta en el período manipulado -dijo Valeria-. Eso significa que los datos son demasiado
-¿Por qué?
-Porque quien fabricó los datos usó una tendencia lineal casi perfecta. En la naturaleza, las ventas no crecen en línea
---
## Prediciendo el futuro (alternativo)
-Y ahora, la pregunta final -dijo Valeria-: si proyectamos la tendencia legítima hacia adelante, ¿qué ventas deberíamos
```

Proyección de la tendencia legítima

Si no hubiera manipulación, ¿qué ventas esperaríamos?

```
pendiente_legitima = (np.mean(ventas_legitimas[12:]) - np.mean(ventas_legitimas[:12])) / 12
intercepto_legitimo = np.mean(ventas_legitimas[:12])
print("=== PROYECCIÓN VS REALIDAD ===")
```

```

print(f'{'Mes':<6} {'Real':<10} {'Proyectado':<12} {'Diferencia':<12}')
print("-" 40)
for i in range(24, 36):
    proyectado = intercepto_legitimo + pendiente_legitima meses[i]
    real = ventas_totales[i]
    diff = real - proyectado
    print(f'{'meses[i]:<6} {'real':<10.1f} {'proyectado':<12.1f} {'diff':<12.1f}')
    diferencia_acumulada = sum(ventas_totales[24:]) - sum(
intercepto_legitimo + pendiente_legitima meses[i] for i in range(24, 36)
)
print(f"\nDiferencia acumulada en 12 meses: {diferencia_acumulada:.0f}")
print(f"Eso es ${diferencia_acumulada 1000:.0f} en ingresos 'extra'")
print("que no pueden explicarse por crecimiento orgánico")

```

Resultado:

=== PROYECCIÓN VS REALIDAD ===

Mes	Real	Proyectado	Diferencia
-----	------	------------	------------

25	85.2	73.8	11.4
----	------	------	------

26	89.7	74.7	15.0
----	------	------	------

27	96.4	75.6	20.8
----	------	------	------

...

36	132.8	83.8	49.0
----	-------	------	------

Diferencia acumulada en 12 meses: 324

Eso es \$324,000 en ingresos 'extra'

que no pueden explicarse por crecimiento orgánico

}

—Más de 300 mil dólares en ventas no explicadas —dijo Valeria—. Eso es lo que el Viceministro tendrá que explicar.

En ese momento, la recepcionista llamó:

—El Viceministro los recibirá ahora.

Valeria cerró su laptop.

—Vamos. Es hora de poner los números sobre la mesa.

Enigmas

Enigma 12.1: Identifica los componentes

Dada la siguiente serie temporal de temperaturas mensuales:

[22, 23, 25, 27, 28, 27, 25, 24, 23, 22, 21, 20]

1. ¿Hay tendencia? ¿Creciente, decreciente o constante?
2. ¿Hay estacionalidad? ¿De cuántos meses?
3. Calcula la media móvil de 3 meses.

Enigma 12.2: Predice el siguiente valor

Si las ventas de los últimos 4 meses fueron [80, 84, 88, 92], ¿cuál sería tu predicción para el quinto mes? ¿Qué método usaste?

Enigma 12.3: Detecta el cambio estructural

Los siguientes datos muestran ventas mensuales. ¿Hay un punto donde el comportamiento cambia drásticamente?

[30, 32, 31, 33, 32, 34, 33, 35, 34, 36, 50, 52, 55, 58, 62]

Lo que aprendiste

- Las series temporales son datos ordenados en el tiempo
- Tendencia: dirección general de largo plazo
- Estacionalidad: patrones que se repiten en períodos fijos
- Residuo: lo que no explican tendencia ni estacionalidad
- Autocorrelación: correlación de la serie consigo misma en el tiempo
- Datos manipulados muestran residuos sistemáticos y autocorrelación anormal

Valeria y Marco entraron al despacho del Viceministro.

Era un hombre de unos sesenta años, traje impecable, sonrisa profesional. Pero cuando Valeria abrió su laptop y comenzó a mostrar los números, la sonrisa se desvaneció.

—Señor Viceministro —dijo Valeria—, tenemos que hablar sobre 324 mil dólares en ventas que no existen.

Capítulo 13: El Último Conjunto (Parte 1)

Conceptos: Repaso integrador — todas las herramientas estadísticas trabajando juntas

El Viceministro los miró con una expresión que Valeria no supo descifrar. ¿Sorpresa? ¿Enojo? ¿Miedo?

—No sé de qué están hablando —dijo.

Valeria colocó su laptop sobre el escritorio y comenzó a mostrar los datos.

—Permítame explicarle con números, señor Viceministro. Comencemos con una prueba de chi-cuadrado sobre los accesos a los servidores del ministerio.

—Usted tuvo 12 accesos nocturnos a los servidores en los últimos 3 meses. La frecuencia esperada para cualquier persona es de 1.2 accesos. Su chi-cuadrado es de 103.2 —el más alto de todos los funcionarios—. La probabilidad de que esto sea casualidad es menor al 0.0001%.

—Accedo a los servidores cuando hay emergencias —dijo el Viceministro—. Es parte de mi trabajo.

—Por supuesto —continuó Valeria—. Pero veamos la correlación entre sus accesos y la manipulación de datos. El coeficiente de correlación es de 0.87. Casi perfecto. Y cuando analizamos la regresión de ventas del medicamento, encontramos que en los meses posteriores a sus accesos, las ventas aumentaron un 46% más de lo esperado.

—Eso no prueba nada.

—Entonces veamos la varianza. La desviación estándar de los datos del ensayo clínico pasó de 2.11 a 0.42 después de que usted accediera a los servidores. El coeficiente de variación se redujo del 2.96% al 0.56%. En 40 años de datos del ministerio, nunca hemos visto un cambio así sin intervención externa.

El Viceministro guardó silencio.

—Y finalmente —dijo Valeria—, la serie temporal. Las ventas del medicamento crecían a un ritmo constante

de 0.8 unidades por mes. De repente, hace 12 meses, el crecimiento se acelera a 3.8 unidades por mes. La diferencia acumulada es de 324 mil dólares en ventas no explicadas.

—¿Dónde quiere llegar? —preguntó el Viceministro, su voz más baja.

—A que usted manipuló los datos del ensayo clínico para que el medicamento pareciera más efectivo. Las ventas se dispararon. Pero Kamila Huamán lo descubrió. Y usted la silenció.

El poder de la estadística integrada

—En estadística —dijo Valeria—, una sola prueba puede ser una coincidencia. Pero cuando cinco pruebas independientes apuntan en la misma dirección, la probabilidad de que sea coincidencia se vuelve esencialmente cero.

```
# Probabilidad combinada de todas las evidencias
import math
# Valores p aproximados de cada evidencia
valores_p = [
    1e-10, # Chi-cuadrado de accesos
    1e-8,  # Correlación IP-manipulación
    1e-12, # Varianza (cambio en CV)
    1e-6,  # Regresión (cambio en pendiente)
    1e-9,  # Serie temporal (diferencia acumulada)
    0.0001, # Desaparición de Sofía y Ramiro
]
# Combinación de Fisher
chi2_combinado = -2 * sum(math.log(p) for p in valores_p)
grados_libertad = 2 * len(valores_p)
# Aproximación: si chi2 > 2*gl, es significativo
print("=== PROBABILIDAD COMBINADA ===")
print(f"Número de pruebas independientes: {len(valores_p)}")
print(f"Chi-cuadrado combinado (Fisher): {chi2_combinado:.2f}")
print(f"Grados de libertad: {grados_libertad}")
print()
print("Interpretación: la probabilidad de que TODAS estas")
print("evidencias sean coincidencias es esencialmente CERO.")
print(f"p < 10^{-int(chi2_combinado/2):d}")
```

Resultado:

```
=== PROBABILIDAD COMBINADA ===
Número de pruebas independientes: 6
Chi-cuadrado combinado (Fisher): 143.56
Grados de libertad: 12
Interpretación: la probabilidad de que TODAS estas
evidencias sean coincidencias es esencialmente CERO.
p < 10^-71
}

-Diez elevado a la menos 71 —dijo Valeria—. Eso es un uno seguido de 71 ceros. No existe en el universo una coincidencia
El Viceministro se levantó y caminó hacia la ventana.
-Tiene razón —dijo—. Manipulé los datos.
Marco dio un paso adelante.
-¿Y Kamila? ¿Usted la mató?
-No —respondió el Viceministro—. No la maté. Pero sé quién lo hizo.
-¿Quién?
-El verdadero culpable no soy yo. Soy solo una pieza. La persona que ordenó todo esto... está más arriba que yo.
Valeria sintió un escalofrío.
-¿El Ministro?
El Viceministro asintió lentamente.
-Y si van tras él, van a necesitar más que estadísticas. Van a necesitar pruebas que no puedan ser refutadas.
-¿Y qué pruebas serían esas?
El Viceministro abrió la gaveta de su escritorio y sacó una memoria USB.
-Aquí están todos los correos. Las transferencias. Las órdenes. Todo. Kamila los encontró antes de morir. Y yo los guard
Valeria tomó la USB.
-¿Por qué nos da esto?
-Porque ya no puedo vivir con esto. Y porque usted tiene razón: los números no mienten.
```

```

---
## Enigmas
### Enigma 13.1: Integración
Tienes tres pruebas independientes con valores p: 0.02, 0.03, y 0.04. ¿Son suficientes para concluir que hay un efecto?
### Enigma 13.2: Revisión del caso
Escribe un resumen estadístico del caso usando al menos 5 de las herramientas aprendidas en los capítulos anteriores.
### Enigma 13.3: Diseña tu investigación
Si fueras Valeria y tuvieras que investigar al Ministro de Salud, ¿qué herramientas estadísticas usarías primero? ¿Por q
---
## Lo que aprendiste
- La integración de múltiples pruebas es más poderosa que una sola
- La combinación de Fisher permite combinar valores p independientes
- La evidencia estadística, cuando es abrumadora, puede confrontar al poder
- Pero la estadística sola no es suficiente: necesita respaldo legal
Valeria guardó la USB.
-Señor Viceministro -dijo-, va a tener que acompañarnos.
-Lo sé.
Salieron del despacho. La USB en manos de Valeria contenía la verdad que Kamila había buscado. Pero la batalla aún no ha
# Capítulo 14: El Último Conjunto (Parte 2)
## Conceptos: El método científico completo – del problema a la conclusión
---
La USB del Viceministro contenía 2,347 archivos. Valeria pasó toda la noche analizándolos mientras Marco dormitaba en un
A las 6 a.m., lo despertó.
-Marco, tengo todo.
-¿Qué tenemos?
-El mapa completo del fraude. El Ministro de Salud, en colaboración con el Viceministro y una farmacéutica internacional
-¿Incluyendo a Kamila?
-Incluyendo a Kamila. Ella encontró el patrón. Y cuando estaba a punto de publicarlo... apareció muerta.
-¿Y Sofía?
-Sofía está viva. Está en Lima, escondida. El Viceministro nos dio su dirección.
---
## El método científico completo
-Antes de ir a la policía, quiero asegurarme de que todo esté documentado -dijo Valeria-. Porque una vez que entreguemos
-¿Cómo lo vas a organizar?
-Siguiendo el método científico. El mismo que Kamila me enseñó.
Valeria abrió su laptop:

```

Documentación del caso siguiendo el método científico

```

print("=" 60)
print("INFORME FINAL: CASO KAMILA HUAMÁN")
print("Fraude en Ensayos Clínicos del Ministerio de Salud")
print("=" 60)
print()

```

1. OBSERVACIÓN

```

print("1. OBSERVACIÓN")
print("-" 40)
print("• La Dra. Kamila Huamán aparece muerta en su laboratorio")
print("• Su computadora muestra un conjunto vacío: datos = [])")
print("• Los datos del ensayo clínico del medicamento G-472 muestran")
print(" resultados sospechosamente perfectos")
print()

```

2. PREGUNTA

```
print("2. PREGUNTA DE INVESTIGACIÓN")
print("-" 40)
print("¿Los datos del ensayo clínico G-472 fueron manipulados")
print("para inflar artificialmente la efectividad del medicamento?")
print("¿Y esta manipulación está relacionada con la muerte de Kamila?")
print()
```

3. HIPÓTESIS

```
print("3. HIPÓTESIS")
print("-" 40)
print("H: Los datos del ensayo son legítimos")
print("H: Los datos fueron manipulados para mostrar resultados falsos")
print()
```

4. PREDICCIÓN

```
print("4. PREDICCIÓN")
print("-" 40)
print("Si H es cierta, debemos encontrar:")
print("• Distribución de datos anormal (Cap. 1)")
print("• Probabilidades extremadamente improbables (Cap. 2)")
print("• Correlación entre accesos y manipulación (Cap. 7)")
print("• Varianza reducida artificialmente (Cap. 10)")
print("• Serie temporal con cambio estructural (Cap. 12)")
print()
```

5. EXPERIMENTACIÓN (recolección de datos)

```
print("5. EXPERIMENTACIÓN")
print("-" 40)
print("Se analizaron 5 fuentes de datos independientes:")
print()
fuentes = [
    ("Logs de acceso al servidor", "5,000 registros", "Cap. 6, 11"),
    ("Datos del ensayo clínico", "1,000 pacientes", "Cap. 1, 4"),
    ("Ventas del medicamento", "36 meses", "Cap. 8, 12"),
    ("Correos y transferencias", "2,347 archivos", "Cap. 13"),
    ("Testimonios", "Ramiro, Sofía, Viceministro", "Cap. 5, 9, 13")
]
for fuente, tamano, capitulo in fuentes:
    print(f" • {fuente} ({tamano}) — {capitulo}")
print()
```

6. ANÁLISIS

```
print("6. ANÁLISIS ESTADÍSTICO")
print("-" 40)
 analisis = [
    "Estadística descriptiva: medias, medianas, rangos anormales",
    "Probabilidad: valores p extremadamente bajos (< 0.00001)",
    "Teorema de Bayes: P(culpable|evidencia) > 0.85",
    "Distribución normal: Z-score de 11.5 en datos clave",
    "Prueba de hipótesis: rechazo de H con 99.99% confianza",
    "Correlación: r = 0.87 entre accesos y manipulación",
    "Regresión: cambio de pendiente de 0.8 a 3.8",
    "Chi-cuadrado:  $\chi^2 = 117.82$ , gl = 4, p < 0.00001",
    "Series temporales: residuos sistemáticos de 11.74"
 ]
for a in analisis:
    print(f" • {a}")
print()
```

7. CONCLUSIÓN

```
print("7. CONCLUSIÓN")
print("-" 40)
print("• SE RECHAZA H: los datos fueron manipulados")
print("• El responsable es el Ministro de Salud")
print("• El móvil: inflar ventas del medicamento G-472")
print(" (beneficio estimado: $3.2 millones)")
print("• La muerte de Kamila Huamán está directamente")
print(" relacionada con el descubrimiento del fraude")
print()
print("=" 60)
print("FIN DEL INFORME")
print("=" 60)
```

Resultado:

=====

INFORME FINAL: CASO KAMILA HUAMÁN

Fraude en Ensayos Clínicos del Ministerio de Salud

=====

1. OBSERVACIÓN

- La Dra. Kamila Huamán aparece muerta en su laboratorio
- Su computadora muestra un conjunto vacío: datos = []

- Los datos del ensayo clínico del medicamento G-472 muestran resultados sospechosamente perfectos

2. PREGUNTA DE INVESTIGACIÓN

¿Los datos del ensayo clínico G-472 fueron manipulados para inflar artificialmente la efectividad del medicamento?

¿Y esta manipulación está relacionada con la muerte de Kamila?

3. HIPÓTESIS

H: Los datos del ensayo son legítimos

H: Los datos fueron manipulados para mostrar resultados falsos

4. PREDICCIÓN

Si H es cierta, debemos encontrar:

- Distribución de datos anormal (Cap. 1)
- Probabilidades extremadamente improbables (Cap. 2)
- Correlación entre accesos y manipulación (Cap. 7)
- Varianza reducida artificialmente (Cap. 10)
- Serie temporal con cambio estructural (Cap. 12)

5. EXPERIMENTACIÓN

Se analizaron 5 fuentes de datos independientes:

- Logs de acceso al servidor (5,000 registros) — Cap. 6, 11
- Datos del ensayo clínico (1,000 pacientes) — Cap. 1, 4
- Ventas del medicamento (36 meses) — Cap. 8, 12
- Correos y transferencias (2,347 archivos) — Cap. 13
- Testimonios (Ramiro, Sofía, Viceministro) — Cap. 5, 9, 13

6. ANÁLISIS ESTADÍSTICO

- Estadística descriptiva: medias, medianas, rangos anormales
- Probabilidad: valores p extremadamente bajos (< 0.00001)
- Teorema de Bayes: $P(\text{culpable}|\text{evidencia}) > 0.85$
- Distribución normal: Z-score de 11.5 en datos clave
- Prueba de hipótesis: rechazo de H con 99.99% confianza
- Correlación: $r = 0.87$ entre accesos y manipulación
- Regresión: cambio de pendiente de 0.8 a 3.8
- Chi-cuadrado: $\chi^2 = 117.82$, $gl = 4$, $p < 0.00001$
- Series temporales: residuos sistemáticos de 11.74

7. CONCLUSIÓN

- SE RECHAZA H: los datos fueron manipulados
- El responsable es el Ministro de Salud
- El móvil: inflar ventas del medicamento G-472 (beneficio estimado: \$3.2 millones)

- La muerte de Kamila Huamán está directamente relacionada con el descubrimiento del fraude

=====

FIN DEL INFORME

=====

```
-Es hermoso -dijo Marco-. Kamila estaría orgullosa.
-No hemos terminado -dijo Valeria-. Ahora tenemos que entregar esto a las autoridades. Y proteger a Sofía.
-¿Y al Viceministro?
-Entregó las pruebas voluntariamente. Eso contará a su favor. Pero tendrá que enfrentar las consecuencias.
Valeria cerró su laptop y miró por la ventana. El sol comenzaba a iluminar Lima.
-¿Sabes qué es lo más irónico de todo esto? -dijo-. Kamila dejó un mensaje en su computadora antes de morir: `datos = []
-¿Y qué significa?
-Que al final, después de todo el análisis, la respuesta más importante no estaba en los números. Estaba en lo que falta
-El conjunto vacío.
-Exacto. El conjunto vacío no es la ausencia de datos. Es la presencia de un crimen.
---
## Epílogo estadístico
-Antes de ir a la policía -dijo Valeria-, quiero hacer una última simulación. Quiero ver qué habría pasado si Kamila no
```

Simulación contrafactual

¿Qué habría pasado si Kamila hubiera vivido?

```
import random
print("=== SIMULACIÓN CONTRAFACTUAL ===")
print("Escenario: Kamila Huamán no es asesinada")
print()
```

Supongamos que Kamila hubiera publicado su descubrimiento

```
resultados_posibles = []
for simulacion in range(1000):
```

Probabilidades estimadas

```
p_publicacion = 0.95 # Habría publicado
p_investigacion = 0.80 # Si publica, habría investigación
p_condena = 0.60 # Si hay investigación, habría condena
p_reforma = 0.30 # Si hay condena, habría reformas
random.seed(simulacion)
if random.random() < p_publicacion:
if random.random() < p_investigacion:
if random.random() < p_condena:
if random.random() < p_reforma:
resultados_posibles.append('Reforma del sistema')
else:
resultados_posibles.append('Condena sin reforma')
```

```

else:
resultados_posibles.append('Investigación sin condena')
else:
resultados_posibles.append('Publicación sin investigación')
else:
resultados_posibles.append('Nunca se publica')
from collections import Counter
conteo = Counter(resultados_posibles)
print("Resultados de 1000 simulaciones:")
for resultado, count in conteo.most_common():
print(f" {resultado}: {count} ({count/10:.1f}%)")

```

Resultado:

=== SIMULACIÓN CONTRAFACTUAL ===

Escenario: Kamila Huamán no es asesinada

Resultados de 1000 simulaciones:

Condena sin reforma: 326 (32.6%)

Investigación sin condena: 220 (22.0%)

Publicación sin investigación: 150 (15.0%)

Reforma del sistema: 228 (22.8%)

Nunca se publica: 76 (7.6%)

```

-En el 22.8% de los casos, habría reformas –dijo Valeria-. Pero Kamila no vivió para verlo.
-Pero nosotros sí –dijo Marco-. Y vamos a asegurarnos de que su muerte no sea en vano.
---
## Enigmas
### Enigma 14.1: Tu propio informe
Escribe un breve informe siguiendo el método científico para un problema que hayas enfrentado (no necesariamente estadís
### Enigma 14.2: Simulación contrafactual
Si la probabilidad de que el Ministro sea condenado es del 70%, y la probabilidad de que enfrente la cárcel si es conden
### Enigma 14.3: Reflexión final
¿Por qué crees que Kamila dejó `datos = []` como mensaje? ¿Qué significa simbólica y estadísticamente?
---
## Lo que aprendiste
- El método científico estructurado: observación → pregunta → hipótesis → predicción → experimentación → análisis →
- La integración de múltiples herramientas estadísticas es más poderosa que usar una sola
- Las simulaciones contrafactuales exploran escenarios alternativos
- A veces, los datos que faltan dicen más que los datos que están presentes
Valeria y Marco salieron del hotel. La USB estaba segura en su mochila. El sol de la mañana limeña iluminaba las calles.
-Vamos –dijo Valeria-. Es hora de terminar esto.
-¿Estás lista?
-Nunca se está listo para enfrentar al poder. Pero los números están de nuestro lado.
Y caminaron hacia la fiscalía.
# Capítulo 15: El Epílogo
## Conceptos: El poder de la estadística en la vida real
---
Tres meses después.
Valeria estaba en el mismo café de San Blas donde había comenzado todo. Frente a ella, una taza de café de muña humeante
La noticia había salido en todos los periódicos:
“Ministro de Salud renuncia tras escándalo de fraude en ensayos clínicos”
El Ministro había sido arrestado. El Viceministro había testificado a cambio de una sentencia reducida. La farmacéutica
Y Kamila... Kamila había recibido justicia póstuma. El ICD había nombrado el laboratorio 7 en su honor: "Laboratorio de
Marco llegó y se sentó frente a ella.
-Lo logramos –dijo.
-Tú lo lograste –respondió Valeria-. Yo solo hice los números.
-Los números que encontraron la verdad.

```

Valeria sonrió. Cerró su laptop.
—¿Sabes qué me dijo Kamila una vez?
—¿Qué?
—Dijo que la estadística no es sobre números. Es sobre personas. Cada punto de datos es una historia. Cada desviación es
—Y tú cambiaste el destino de Kamila.
—No. Kamila cambió el mío. Me enseñó que los números no mienten. Que las personas, sí. Pero los números... los números s
Valeria abrió su laptop una vez más.
—Hay una última cosa que quiero hacer.
—¿Qué?
—Cerrar el círculo.
Abrió Python y escribió:

Cerrando el círculo

El mensaje que comenzó todo

```
datos = [] # El conjunto vacío de Kamila
```

Tres meses después, el conjunto ya no está vacío

```
datos = [  
'Justicia para Kamila',  
'Fraude expuesto',  
'Ministro arrestado',  
'Vidas salvadas',  
'La verdad siempre encuentra su camino'  
]  
for verdad in datos:  
    print(f" {verdad}")  
print()  
print("Conjunto final: no vacío.")  
print("La verdad siempre prevalece.")
```

Resultado:

```
Justicia para Kamila  
Fraude expuesto  
Ministro arrestado  
Vidas salvadas  
La verdad siempre encuentra su camino  
Conjunto final: no vacío.  
La verdad siempre prevalece.
```

```
—El conjunto vacío ya no está vacío —dijo Valeria—. Y eso es lo que Kamila quería.  
—¿Y ahora qué? —preguntó Marco.  
—Ahora... ahora voy a terminar lo que Kamila empezó. Voy a crear un sistema de detección de fraudes estadísticos para el  
—¿Necesitas ayuda?  
—Siempre.  
Marco sonrió.  
—Entonces empecemos.  
---  
## Reflexión final  
La estadística no es una colección de fórmulas aburridas. Es un superpoder. La capacidad de ver patrones donde otros sol  
En este libro, has aprendido:
```

```

- Estadística descriptiva: media, mediana, moda, varianza, desviación estándar
- Probabilidad: regla de Laplace, eventos independientes, probabilidad condicional
- Teorema de Bayes: actualizar creencias con nueva información
- Distribución normal: la campana de Gauss, Z-scores, regla empírica
- Muestreo: población, muestra, sesgo de selección
- Prueba de hipótesis:  $H_0$ ,  $H_1$ , valor p, significancia
- Correlación y regresión: relaciones entre variables, predicción
- Chi-cuadrado: tablas de contingencia, bondad de ajuste
- Series temporales: tendencia, estacionalidad, autocorrelación
Pero más importante: has aprendido a pensar estadísticamente. A cuestionar los datos. A buscar la historia detrás de
Y eso, querido lector, es el verdadero poder de la estadística.
---
FIN
# Conclusión
Has llegado al final de Estadística Mortal: El Enigma del Conjunto Vacío.
Pero esto no es un final. Es un comienzo.
Cada concepto que has aprendido en este libro –desde la media hasta el chi-cuadrado, desde Bayes hasta las series temporales–
Ahora tienes el poder de:
- Cuestionar los datos que te presentan
- Detectar manipulaciones y fraudes
- Tomar decisiones informadas basadas en evidencia
- Contar historias con números
Recuerda siempre las lecciones de Kamila Huamán y Valeria Quispe:
1. Los números no mienten, pero las personas sí
  - Siempre pregunta quién recolectó los datos y por qué
2. La correlación no implica causalidad
  - Busca variables ocultas antes de saltar a conclusiones
3. Un valor p no es la verdad absoluta
  - Es una herramienta, no un veredicto
4. Los datos atípicos son los más interesantes
  - No los ignores; investiga por qué están ahí
5. El conjunto vacío puede contener más información que uno lleno
  - Los datos que faltan también importan
Gracias por acompañar a Valeria y Marco en esta aventura. Espero que hayas disfrutado el viaje tanto como ellos.
Y recuerda: cuando tengas dudas, mira los datos. Ellos siempre tienen la respuesta.
– Alex Goyzueta Delgado
Barcelona, 2026
# Apéndice: Soluciones a los Enigmas
## Capítulo 1: El Conjunto Vacío
### Enigma 1.1

```

```
edades = [29, 34, 45, 45, 45, 52, 67, 71, 34, 29, 45, 38, 52, 45, 29]
```

```
media = sum(edades) / len(edades)
```

media = 43.07

```
edades.sort()
```

```
mediana = edades[len(edades)//2]
```

mediana = 45

```
from collections import Counter
```

```
moda = Counter(edades).most_common(1)[0]
```

moda = 45 (aparece 5 veces)

```
minimo = min(edades) # 29
```

```
maximo = max(edades) # 71
```

```
### Enigma 1.2
```

```
edades.append(98)
```

```
media = sum(edades) / len(edades) # 46.44 (aumentó)
```

```
edades.sort()
```

```
mediana = edades[len(edades)//2] # 45 (igual)
```

```
La media se ve afectada por el valor extremo (outlier). La mediana es robusta y no cambia.
```

```
### Enigma 1.3
```

```
Porcentaje = 5/47 × 100 = 10.6%. Los valores de presión sanguínea faltantes podrían ocultar que los pacientes con presión sanguínea alta son más numerosos que los que tienen presión normal.
```

```
## Capítulo 2: La Probabilidad del Crimen
```

```
### Enigma 2.1
```

```
Probabilidad teórica:  $1/6 \approx 0.1667$  por cada cara.
```

```
Las frecuencias observadas se desvían de lo esperado (100 por cara). El 6 aparece solo 72 veces, mucho menos de lo esperado.
```

```
### Enigma 2.2
```

```
1.  $P(\text{acceso}) = 3/8 = 0.375$ 
```

```
2.  $P(\text{motivo}) = 4/8 = 0.5$ 
```

```
3.  $P(\text{ambos}) = 2/8 = 0.25$ 
```

```
### Enigma 2.3
```

```
import random
```

```
caras = sum(1 for _ in range(10000) if random.random() < 0.5)
```

```
print(f"Caras: {caras}, Prob: {caras/10000:.4f}")
```

Debería obtener ~0.5